

Extensões do método ponto proximal para a minimização de composição de funções

Vitaliano S. Amaral – UFPI

XLIV Congresso Nacional de Matemática Aplicada e Computacional



CCN
Centro de Ciências da
Natureza - UFPI



Setembro de 2025

Método do Ponto Proximal

Dado o problema

$$\min f(x) \quad \text{sujeito a } x \in \mathbb{R}^n \quad (1)$$

onde $f: \mathbb{R}^n \rightarrow \mathbb{R}$.

O Método do Ponto Proximal - PPM para resolver o Problema (1) consiste em gerar uma sequência x^k tal que

$$x^{k+1} \in \arg \min_{x \in \mathbb{R}^n} f(x) + \frac{1}{2\alpha_k} \|x - x^k\|^2.$$

Martinet¹ e Rockafellar² foram pioneiros em estudar esse tipo de métodos.

¹B. Martinet, *Brève communication. Régularisation d'inéquations variationnelles par approximations successives*. Revue française d'informatique et de recherche opérationnelle. Série rouge 4.R3 (1970), pp. 154–158.

²R. T. Rockafellar, *Monotone operator and the proximal point algorithm*. SIAM J. Control Optim. 14 (1976), pp. 877–898.

Extensões do PPM

O **PPM** foi estendido para composição de funções.

- ▶ No trabalho³, foi proposto uma versão **exata** do PPM para

$$\min_{x \in \mathbb{R}^n} f(x) := g_1(x) + g_2(x) - h(x), \quad (2)$$

com g_1 semicontínua inferior, ∇g_2 Lipschitz e h convexa.

- ▶ Recentemente foi proposto extensões do PPM para o problema

$$\min_{x \in \mathbb{R}^n} f(x) := g_1(x) + g_2(x) + h(x). \quad (3)$$

Em⁴ foi estudado o caso em que g_1, g_2, h são convexas.

Em⁵ o caso **não convexo**, com g_1 diferenciável. e g_2, h convexas.

³N.T. An, N.M. Nam, *Convergence analysis of a proximal point algorithm for minimizing differences of functions*, Optim., 66(1) (2017), 129–147.

⁴A. Yurtsever, V. Mangalick, and S. Sra, *Three operator splitting with subgradients, stochastic gradients, and adaptive learning rates*. NeurIPS (2021).

⁵A. Yurtsever, V. Mangalick, and S. Sra, *Three Operator Splitting with a Nonconvex Loss Function*, ICML (2021).

Extensões do PPM

Recentemente, (Amaral, V.S., Lopes, J.O., Santos, P.S.M., Silva, G.N.)⁶, foi proposto uma versão **inexata** do PPM para o problema

$$\min_{x \in \mathbb{R}^n} f(x) := g_1(x) + g_2(x) - h(x),$$

assumindo:

- ▶ $g_1 : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ própria e semicontínua inferior
- ▶ g_2 diferenciável com gradiente Hölder
- ▶ h convexa, possivelmente não diferenciável.

⁶Amaral, V.S., Lopes, J.O., Santos, P.S.M., Silva, G.N. (2024). *On the complexity of a quadratic regularization algorithm for minimizing nonsmooth and nonconvex functions*. OMS, 40(1), 1–23. <https://doi.org/10.1080/10556788.2024.2368578>.

Inexact proximal-type algorithm (IPTA)

O método IPTA: $x^0 \in \mathbb{R}^n$, $\alpha, \theta, \epsilon \in (0, 1)$, $f_{\text{target}} \in \mathbb{R}$, $\rho_{\min} > 0$, $\eta > 0$.

Passo 1: Escolha $\epsilon_k \leq (\eta/\rho_k)^2$, calcule $w^k \in \partial_{\epsilon_k} h(x^k)$ e considere

$$M_{x^k, \rho_k}(x) = g_1(x) + g_2(x^k) - h(x^k) + \langle \nabla g_2(x^k) - w^k, x - x^k \rangle + \rho_k \|x - x^k\|^2.$$

Passo 2: Encontre \bar{x}^{k+1} tal que $M_{x^k, \rho_k}(\bar{x}^{k+1}) \leq f(x^k)$ e

$$d(0, \partial^L g_1(\bar{x}^{k+1}) + \nabla g_2(x^k) + 2\rho_k(\bar{x}^{k+1} - x^k) - w^k) \leq \theta \|\bar{x}^{k+1} - x^k\|.$$

Passo 3: Se $d(0, \partial^L g_1(\bar{x}^{k+1}) + \nabla g_2(x^k) - w^k) < \epsilon$ ou $f(\bar{x}^{k+1}) \leq f_{\text{target}}$, **parar**.

Passo 4: Se

$$f(\bar{x}^{k+1}) \leq f(x^k) - \frac{\alpha}{36\rho_k} \epsilon^2,$$

fazer $x^{k+1} = \bar{x}^{k+1}$, $\rho_{k+1} = \rho_k$, $k \leftarrow k + 1$ e voltar ao Passo 1; caso contrário $\rho_k \leftarrow 2\rho_k$ e voltar ao Passo 1.

Boa definição

- ▶ Coercividade de $M_{x^k, \rho_k}(x)$ garante a boa definição do Passo 2.
- ▶ Assumindo

$$g_2(y) \leq g_2(x) + \langle \nabla g_2(x), y - x \rangle + L \|y - x\|^{\beta+1}, \quad L > 0, \quad \beta \in (0, 1],$$

provamos que

$$f(\bar{x}^{k+1}) \leq f(x^k) - \frac{\alpha}{36\rho} \epsilon^2.$$

sempre que

$$\rho \geq \max \left\{ 1, \frac{\theta}{4}, \left[\frac{L}{1-\alpha} \left(\frac{\epsilon}{6} \right)^{\beta-1} + \frac{\eta^2}{1-\alpha} \left(\frac{\epsilon}{6} \right)^{-2} \right]^{\frac{1}{\beta}} \right\}.$$

Complexidade do IPTA

- ▶ Números de iterações é limitado superiormente por:

$$\frac{36\gamma(f(x^0) - f_{\text{target}})}{\alpha} \max \left\{ \epsilon^{-\frac{\beta+1}{\beta}}, \eta^{\frac{2}{\beta}} \epsilon^{-\frac{2(\beta+1)}{\beta}} \right\}.$$

- ▶ Número de avaliações de f e seus subdiferenciais é limitado superiormente por:

$$\frac{36\gamma(f(x^0) - f_{\text{target}})}{\alpha} \max\{\epsilon^{-\frac{\beta+1}{\beta}}, \eta^{\frac{2}{\beta}} \epsilon^{-\frac{2(\beta+1)}{\beta}}\} + \log_2\left(\frac{\gamma}{\rho_{\min}}\right).$$

com

$$\gamma := 2 \max \left\{ 1, \frac{\theta}{4}, \left[\frac{6^{1-\beta} L}{1-\alpha} + \frac{36}{1-\alpha} \right]^{1/\beta}, \rho_{\min} \right\}.$$

O método IPTA pode resolver vários casos clássicos:

- ▶ **Caso diferenciável:** se $g_1 \equiv h \equiv 0$

$$\min_x g_2(x).$$

- ▶ **Função DC:** se $g_1 + g_2$ é convexa,

$$\min_x f(x) = g(x) - h(x), \quad g = g_1 + g_2.$$

- ▶ **Restrições convexas:** para C convexo,

$$\min_{x \in C} f(x) = g_2(x) - h(x),$$

usando $g_1 = \delta_C$ (função indicadora de C).

► o problema do lasso

$$\min_{x \in \mathbb{R}^n} \left\{ \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1 \right\}, \lambda > 0, A \in \mathbb{R}^{s \times n}, \quad (4)$$

considerando $g_1(x) = \lambda \|x\|_1$, $g_2(x) = \frac{1}{2} \|Ax - b\|^2$ e $h = 0$.

► o problema

$$\min \{ \|Ax - b\|^2 : 0 \leq x_i \leq 1, i = 1, 2, \dots, n \} \quad (5)$$

onde $A \in \mathbb{R}^{s \times n}$ e $b \in \mathbb{R}^s$.

Basta minimizar $f(x) = g_1(x) + g_2(x)$ com $g_1(x) = \delta_{\Omega}(x)$,
 $\Omega = \{x \in \mathbb{R}^n : 0 \leq x_i \leq 1, i = 1, 2, \dots, n\}$, $g_2(x) = \|Ax - b\|^2$.

- **Problema de mínimos quadrados penalizado por norma L_p**
($1 < p < 2$):

$$\min f(x) = \frac{1}{2} \|A(x) - b\|_2^2 + \frac{\lambda}{p} \|\Phi(x)\|_p^p,$$

onde $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ é diferenciável (não necessariamente linear),
 $b \in \mathbb{R}^m$, e Φ é operador linear.

Detalhes em:



A. Bernigaud, S. Gratton and E. Simon, A non-linear conjugate gradient in dual space for L_p -norm regularized non-linear least squares with application in data assimilation, *Numerical Algorithms*, **95**, 471–497 (2024).

<https://doi.org/10.1007/s11075-023-01578-x>

Testes Numéricos – Exemplo 2

Problema de regularização ℓ_1 :

$$\min_x \frac{1}{2} \|Ax - b\|^2 + \lambda \|x\|_1,$$

com parâmetro $\lambda = 5 \times 10^{-5}$.

Configuração:

- ▶ Critério de parada: $\frac{\|x^k - x^{k-1}\|}{\|x^{k-1}\|} < \epsilon$.
- ▶ Métrica de avaliação: **PSNR**, definida por

$$\text{PSNR}(x_k) = 10 \log_{10} \left(\frac{255^2}{\text{MSE}} \right), \quad \text{MSE} = \frac{1}{mn} \|x_k - \bar{x}\|^2,$$

onde \bar{x} é a imagem original.

Comparação com IMA e FISTA

Comparamos o IPTA com o FISTA(Fast iterative shrinkage-thresholding algorithm) seguindo⁷

Algoritmo	CPU (s)	Iterações	PSNR
FISTA	4.49	476	34.43
IPTA	0.89	435	28.63



(a) Original

(b) Desfocada

(c) FISTA

(d) IPTA

- ▶ O IPTA tem bom tempo de CPU.
- ▶ O FISTA apresenta um PSNR mais alto do que o IMA e o IPTA.

⁷R. Wattanataweekul, and K. Janngam, *An accelerated common fixed point algorithm for a countable family of G-nonexpansive mappings with applications to image recovery*. J. Inequal. Appl. 2022 (2022), pp. 1–15.

Algumas outras extensões

Versões BCD⁸: Problema

$$\min_{x \in \mathbb{R}^n} F(x) := f(x) + g(x).$$

Para cada $i = 1, \dots, q$ calcula $x^{k,i} = x^{k,i-1} + U_i s_{(i)}^k$ onde $s_{(i)}^k \in \mathbb{R}^{n_i}$ é uma solução do problema

$$\min_{s \in \mathbb{R}^{n_i}} \Psi_k(s) + \frac{\rho_k}{2} \|s\|^2,$$

onde $\Psi_{k,i-1}(x) =$

$$\langle U_i^T \varphi_f(x^{k,i-1}, \lambda_k), s \rangle + \frac{1}{2} \langle B_{(i)}(x^{k,i-1})s, s \rangle + h(x^k + U_i s) - h(x^{k,i-1}).$$

► **Complexidade:** $\mathcal{O}\left(\epsilon^{-\frac{\beta+1}{\beta}}\right)$.

⁸Amaral, V. (2025). - *A partially derivative-free cyclic block coordinate descent method for nonseparable composite optimization*. Mathematical Modelling and Analysis, 30(3), 535-552.

Algumas outras extensões

- **Problemas Multiobjetivo:** V.S. Amaral, P.B. Assunção, D.R. Souza⁹ propuseram um método para

$$\min_{x \in \mathbb{R}^n} F(x), \quad F: \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad F_j = f_j + h_j, \quad j = 1, \dots, m.$$

Os subproblemas aproximados têm a forma

$$\min_{x \in \mathbb{R}^n} \Phi_{x^k}(x) + \frac{\sigma_k}{2} \|x - x^k\|^2,$$

com

$$\Phi_{x^k}(x) = \max_j \left[\langle g_{f_j}(x^k, \lambda_k) + \frac{1}{2} B_j^k(x - x^k), x - x^k \rangle + h_j(x) - h_j(x^k) \right].$$

⁹V.S. Amaral, P.B. Assunção, D.R. Souza, *A partially derivative-free proximal method for composite multiobjective optimization in the Hölder setting*, arXiv:2508.20071 (2025).