

# Avanços Recentes nos Métodos de Descida Coordenada por Blocos

Vitaliano de Sousa Amaral

Departamento de Matemática  
Universidade Federal do Piauí – UFPI



2026

# Métodos de descida coordenada por blocos

Problemas de otimização em aplicações reais são frequentemente de grande escala e computacionalmente exigentes.

Nesse contexto, métodos de descida coordenada por blocos (BCD) representam uma alternativa atrativa.

## Ideia central dos métodos BCD

Atualizar apenas um bloco de variáveis a cada iteração, mantendo os demais fixos.

## Por que utilizar métodos BCD?

- ▶ **Menor custo por iteração:** apenas parte das variáveis é atualizada;
- ▶ **Exploração da estrutura:** os blocos podem representar diferentes grupos de variáveis;

# Ideia fundamental dos métodos BCD

Consideramos problemas de otimização da forma

$$\min_{x \in \Omega} F(x) := f(x) + g(x)$$

em que

- ▶  $\Omega \subset \mathbb{R}^n$ ;
- ▶  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  é diferenciável;
- ▶  $g : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  pode ser não suave.

## Estrutura do problema

A função  $f$  representa a parte suave do problema, enquanto  $g$  pode incorporar termos de regularização, não suavidade ou restrições.

## Exemplo motivador

Um exemplo importante é o problema de mínimos quadrados não linear regularizado pela norma  $\ell_\theta$ :

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|A(x) - b\|_2^2 + \frac{\lambda}{\theta} \|\Phi(x)\|_\theta^\theta$$

em que:

- ▶  $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$  é diferenciável, mas não necessariamente linear;
- ▶  $b \in \mathbb{R}^m$  representa o vetor de dados;
- ▶  $\Phi$  é um operador linear e  $\lambda > 0$  é o parâmetro de regularização.

Esse problema pode ser escrito como  $F = f + g$ , considerando

$$f(x) = \frac{1}{2} \|A(x) - b\|_2^2, \quad g(x) = \frac{\lambda}{\theta} \|\Phi(x)\|_\theta^\theta.$$

# Ideia básica dos métodos BCD

- 1 Escolher um bloco  $i_k \subset \{1, 2, \dots, n\}$ .
- 2 Construir um modelo  $m_{i_k}(x^k, \cdot)$  para a função no bloco escolhido.
- 3 Determinar  $s^k \in \mathbb{R}^{n_{i_k}}$  tal que

$$s_k \in \arg \min_{s \in \mathbb{R}^{n_{i_k}}} m_{i_k}(x^k, s).$$

- 4 Definir

$$x^{k+1} \text{ onde } x_j^{k+1} = \begin{cases} x_j^k + s_j^k, & j \in I_{i_k}, \\ x_j^k, & j \notin I_{i_k}. \end{cases}$$

## Uma vantagem

O subproblema tem dimensão  $n_{i_k}$ , frequentemente muito menor que  $n$ .

# Estacionariedade

Para o problema composto

$$\min_{x \in \mathbb{R}^n} f(x) + g(x),$$

a condição de estacionariedade é

$$0 \in \nabla f(\bar{x}) + \partial^L g(\bar{x}),$$

em que  $\partial^L g(\bar{x})$  denota o subdiferencial limite.

Uma medida natural de estacionariedade é

$$\text{dist}(0, \nabla f(\bar{x}) + \partial^L g(\bar{x})).$$

## Estacionariedade aproximada

Dizemos que  $\bar{x}$  é  $\varepsilon$ -estacionário se

$$\text{dist}(0, \nabla f(\bar{x}) + \partial^L g(\bar{x})) \leq \varepsilon.$$

# Estacionariedade por blocos

Uma medida associada ao bloco  $i$  é

$$\text{dist} \left( 0, \nabla_{(i)} f(x) + \partial_{(i)}^L g(x) \right).$$

A condição de estacionariedade por blocos é

$$\text{dist} \left( 0, \nabla_{(i)} f(x) + \partial_{(i)}^L g(x) \right) = 0, \quad i = 1, \dots, r.$$

Para estacionariedade aproximada, pode-se testar

$$\text{dist} \left( 0, \nabla_{(i)} f(x) + \partial_{(i)}^L g(x) \right) \leq \frac{\varepsilon}{r}, \quad i = 1, \dots, r.$$

## Pergunta fundamental

Essas condições implicam

$$\text{dist} \left( 0, \nabla f(\bar{x}) + \partial^L g(\bar{x}) \right) \leq \varepsilon?$$

## Quando a implicação é verdadeira?

- ▶ Quando  $g$  é diferenciável.

Neste caso temos

$$\begin{aligned}\text{dist}(0, \nabla f(\bar{x}) + \partial^L g(\bar{x})) &= \|\nabla f(\bar{x}) + \nabla g(\bar{x})\| \\ &\leq \sum_{i=1}^r \|\nabla_{(i)} f(\bar{x}) + \nabla_{(i)} g(\bar{x})\| \leq \varepsilon.\end{aligned}$$

- ▶ Quando  $g$  é uma função tal que

$$\partial^L g(x) = \partial_{(1)}^L g(x) \times \cdots \times \partial_{(r)}^L g(x).$$

Neste caso

$$\text{dist}(0, \nabla f(\bar{x}) + \partial^L g(\bar{x}))^2 \leq \sum_{i=1}^r \text{dist}(0, \nabla_{(i)} f(\bar{x}) + \partial_{(i)}^L g(\bar{x}))^2 \leq \varepsilon^2.$$

## Quando a implicação pode falhar?

Quando existe termo não suave e não separável a implicação pode falhar.

Por exemplo, se

$$F(x, y) = x + y + \frac{x^2 + y^2}{2} + |x - y|.$$

Para este caso, temos

$$\partial_{(1)}^L F(0, 0) = \partial_{(2)}^L F(0, 0) = [0, 2].$$

Porém

$$(0, 0) \notin \partial F(0, 0) = \{(1 + t, 1 - t) : t \in [-1, 1]\}.$$

Mais precisamente, para  $\epsilon = \frac{1}{2}$  temos

$$\text{dist}(0, \partial_{(1)} F(0, 0)) = \text{dist}(0, \partial_{(2)} F(0, 0)) = 0 < \frac{\epsilon}{2} \text{ e } \text{dist}(0, \partial F(0, 0)) = \sqrt{2} > \epsilon.$$

Para este exemplo o minimizador global é  $x^* = (-1, -1)$ .

# Convergência dos métodos BCD

Vimos que, em geral, a estacionariedade por blocos não implica a estacionariedade global.

Consequentemente, a convergência para um ponto estacionário por blocos pode não garantir a convergência para um ponto estacionário do problema.

## Questões fundamentais

- ▶ Como garantir a convergência para um ponto estacionário por blocos?
- ▶ Sob quais condições a estacionariedade por blocos implica a estacionariedade global?
- ▶ Como assegurar a convergência para um ponto estacionário global sem comprometer o baixo custo computacional dos métodos BCD?

As respostas a essas questões dependem diretamente da estratégia de escolha dos blocos e do modelo utilizado.

# Avanços recentes nos métodos BCD

Nos últimos anos, diversas abordagens para os métodos BCD têm sido propostas, combinando diferentes:

- ▶ estratégias para a escolha dos blocos;
- ▶ modelos aproximados para os subproblemas.

Essas escolhas influenciam diretamente o custo computacional por iteração, as propriedades de convergência e a complexidade dos métodos.

Para problemas do tipo

$$\min_{x \in \Omega} F(x) := f(x) + g(x),$$

geralmente é utilizado modelo do tipo:

$$m_{i_k}(x_k, s) = T_{p, i_k}(x_k, s) + g(x_k + U_{i_k} s) + \frac{\sigma}{p+1} \|s\|^{p+1},$$

em que  $T_{p, i_k}(x, s)$  é um modelo aproximado para  $f(x + U_{i_k} s)$  em  $\mathbb{R}^{n_{i_k}}$ .

Amaral, Andreani, Birgin, Marcondes e Martínez

*On complexity and convergence of high-order coordinate descent algorithms for smooth nonconvex box-constrained minimization.* Journal of Global Optimization, 2022.

|                  | Minimização por blocos                                                           | Tradicionais                                |
|------------------|----------------------------------------------------------------------------------|---------------------------------------------|
| <b>Problema</b>  | $\min_{\ell \leq x \leq u} f(x)$                                                 | -                                           |
| <b>Modelo</b>    | $T_{p,i_k}(x_k, s) + \frac{\sigma}{p+1} \ s\ ^{p+1}, s \in \mathbb{R}^{n_{i_k}}$ | -                                           |
| <b>Blocos</b>    | A cada $\bar{m}$ iterações todos os blocos sejam visitados                       | -                                           |
| <b>Hipóteses</b> | Condições de Lipschitz                                                           | -                                           |
| <b>Complex.</b>  | $\mathcal{O}(\varepsilon^{-(p+1)})$                                              | $\mathcal{O}(\varepsilon^{-\frac{p+1}{p}})$ |

## Birgin e Martínez

*Block coordinate descent for smooth nonconvex constrained minimization.* Computational Optimization and Applications, 2022.

|                  | Minimização por blocos                                                                                                             | Tradicionais                    |
|------------------|------------------------------------------------------------------------------------------------------------------------------------|---------------------------------|
| <b>Problema</b>  | $\min f(x_1, \dots, x_{n_r}) \quad \text{s.a. } x_i \in \Omega_i, i = 1, \dots, n_r.$                                              | -                               |
| <b>Modelo</b>    | $\nabla_{i_k} f(x^k)^T (s - x_{i_k}^k) + \frac{1}{2} (s - x_{i_k}^k)^T B_k (s - x_{i_k}^k) + \frac{\sigma}{2} \ s - x_{i_k}^k\ ^2$ | -                               |
| <b>Blocos</b>    | A cada $\bar{m}$ iterações todos os blocos sejam visitados                                                                         | -                               |
| <b>Hipóteses</b> | Condições de Lipschitz                                                                                                             | -                               |
| <b>Complex.</b>  | $\mathcal{O}(\varepsilon^{-2})$                                                                                                    | $\mathcal{O}(\varepsilon^{-2})$ |

## Necoara e Chorobura

*Random Coordinate Descent Methods for Nonseparable Composite Optimization.* SIAM Journal on Optimization, 2023.

|                  | Minimização por blocos                                                                                           | Tradicionais                    |
|------------------|------------------------------------------------------------------------------------------------------------------|---------------------------------|
| <b>Problema</b>  | $\min F(x) := f(x) + \psi(x) \quad \text{s.a. } x \in \mathbb{R}^n.$                                             | -                               |
| <b>Modelo</b>    | $f(x_k) + \langle U_{i_k}^T \nabla f(x_k), s \rangle + \frac{H_{f, U_{i_k}}}{2} \ s\ ^2 + \psi(x_k + U_{i_k} s)$ | -                               |
| <b>Blocos</b>    | Uniformemente randômica ou cíclica                                                                               | -                               |
| <b>Hipóteses</b> | Condições de Lipschitz e Kurdyka-Lojasiewicz                                                                     | -                               |
| <b>Complex.</b>  | $\mathcal{O}(\varepsilon^{-2})$                                                                                  | $\mathcal{O}(\varepsilon^{-2})$ |

## Amaral

*A partially derivative-free cyclic block coordinate descent method for nonseparable composite optimization.* Mathematical Modelling and Analysis, 2025..

|                  | Minimização por blocos                                                                                                                                                      | Tradicionais                                        |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------|
| <b>Problema</b>  | $\min F(x) := f(x) + h(x) \quad \text{s.a. } x \in \mathbb{R}^n.$                                                                                                           | -                                                   |
| <b>Modelo</b>    | $\langle \varphi_{\lambda_k}^f(x_{(i-1)}^k), s \rangle + \frac{1}{2} \langle B_{(i)}^k s, s \rangle + h(x_{(i-1)}^k + U_i s) - h(x_{(i-1)}^k) + \frac{\sigma_k}{2} \ s\ ^2$ | -                                                   |
| <b>Blocos</b>    | Cíclico                                                                                                                                                                     | -                                                   |
| <b>Hipóteses</b> | Condições de Holder                                                                                                                                                         | -                                                   |
| <b>Complex.</b>  | $\mathcal{O}(\varepsilon^{-\frac{1+\beta}{\beta}})$                                                                                                                         | $\mathcal{O}(\varepsilon^{-\frac{1+\beta}{\beta}})$ |

## Amaral, Andreani, Secchin e Silva

*A flexible block coordinate descent method for unconstrained optimization under Hölder continuity.* Computational Optimization and Applications, 2026.

|                  | Minimização por blocos                                                                                      | Tradicionais                                     |
|------------------|-------------------------------------------------------------------------------------------------------------|--------------------------------------------------|
| <b>Problema</b>  | $\min f(x) \quad \text{s.a. } x \in \mathbb{R}^n.$                                                          | -                                                |
| <b>Modelo</b>    | $\langle \nabla_{(i)} f(x^k), s \rangle + \frac{1}{2} \langle B_{(i)}(x^k) s, s \rangle + \sigma_k \ s\ ^2$ | -                                                |
| <b>Blocos</b>    | $\ \nabla_{(i)} f(x^k)\ _\infty > \epsilon$                                                                 | -                                                |
| <b>Hipóteses</b> | Condições de Holder                                                                                         | -                                                |
| <b>Complex.</b>  | $\mathcal{O}(\epsilon^{-\frac{1+\beta}{\beta}})$                                                            | $\mathcal{O}(\epsilon^{-\frac{1+\beta}{\beta}})$ |

# Obrigado!

Vitaliano de Sousa Amaral

Departamento de Matemática  
Universidade Federal do Piauí

`vitalianoamaral@ufpi.edu.br`  
`https://vitalianoamaral.github.io`