Um método de suavização para resolver problemas quadráticos convexos separáveis do tipo knapsack

Vitaliano S. Amaral – UFPI
Programa de Pós-graduação
em Matemática - PPGMat

Trabalho em conjunto com A. Alves, J. O. L. Silva,
P. S. M. Santos e S. S. Souza

XVIII Simpósio de Análise Numérica e Otimização

Programa de Verão em Matemática da UFPR.

Sumário

Introdução

Reformulação do Problema
- Reformulação do Problema

Aproximações Suaves
- Aproximações Suaves

O Método Proposto
- Smoothing Gradient-Type Algorithm (SGTA)
- Complexidade

Experimentos Numéricos

Introdução

Em nosso trabalho, consideramos o seguinte problema :

$$\begin{cases} \min\limits_{x} & \frac{1}{2}x^T P x - a^T x \\ \text{s.a.} & b^T x = c \\ & \ell \leqslant x \leqslant u, \end{cases} \tag{1}$$

onde:

- $\rightarrow$ $x \in \mathbb{R}^n$ é a variável de decisão.
- $\rightarrow$ $P \in \mathbb{R}^{n \times n}$ é uma matriz diagonal com elementos da diagonal $p_i > 0$, para todo $i = 1, \ldots, n$.
- $\rightarrow$ $a, b, \ell, u \in \mathbb{R}^n$ são vetores com componentes a_i, b_i, ℓ_i, u_i onde $b_i \neq 0$ e $\ell_i < u_i$ para todo $i = 1, \ldots, n$.
- $\rightarrow$ c é um escalar positivo.

Introdução

Em nosso trabalho, propomos um algoritmo baseado no método do gradiente com regularização quadrática para resolver uma versão modificada do Problema (1), utilizando uma suavização do operador de projeção sobre uma caixa.

O Problema (1) é transformado no seguinte problema de encontrar a raiz da função

$$\begin{cases} g(\lambda) = 0, \\ \lambda \in \mathbb{R}. \end{cases} \tag{2}$$

onde $g(\lambda) := \sum_{i=1}^{n} b_i x_i(\lambda) - c,\ x(\lambda) = (x_1(\lambda), x_2(\lambda), \ldots, x_n(\lambda))$,

e $x_i(\lambda) = \text{proj}_{[\ell_i, u_i]}\left(\frac{\lambda b_i + a_i}{p_i}\right), \quad i = 1, 2, \ldots, n.$

A função g resultante dessa reformulação é linear por partes e não diferenciável.

Introdução

A não diferenciabilidade dificulta o uso de métodos baseados em derivadas. Por isso, **técnicas de suavização** têm sido amplamente estudadas.

→ **Bertsekas**[1] utilizou aproximações suaves para problemas não diferenciáveis envolvendo termos do tipo $\max(0, f_i(x))$.

→ Chen et al.[2] propuseram aproximações suaves para problemas de complementaridade baseadas na função $\max(0, \cdot)$.

→ **Venceslau**[3] empregou suavização hiperbólica e mostrou sua relação com ε-subgradientes em certos casos.

---

[1] D. Bertsekas, Nondifferentiable Optimization Via Approximation Urbana, University of Illinois, 1974.

[2] B. Chen and P.T.Harker, Smooth approximations to nonlinear complementarity problems, SIAM J. Optim. 7 (1987), pp. 403–420.

[3] H.M. Venceslau, Subgradiente Diferenciável via suavização hiperbólica – Rio de Janeiro: UFRJ/COPPE, 2013.

Sumário

Introdução

Reformulação do Problema
- Reformulação do Problema

Aproximações Suaves
- Aproximações Suaves

O Método Proposto
- Smoothing Gradient-Type Algorithm (SGTA)
- Complexidade

Experimentos Numéricos

Reformulação do Problema

Nossa abordagem é inspirada no método de Newton não suave de Cominetti et al.[4], com uma diferença essencial: **o algoritmo proposto não requer cálculo de derivadas**.

As condições KKT para o Problema (1) são dadas por:

$$
\begin{aligned}
&\sum_{i=1}^{n} b_i x_i = c \\
&\ell_i \leqslant x_i \leqslant u_i, \quad i = 1, 2, \ldots, n \\
&x_i p_i - a_i - \lambda b_i - \mu_i + \omega_i = 0, \quad i = 1, 2, \ldots, n \\
&\mu_i(\ell_i - x_i) = 0, \quad i = 1, 2, \ldots, n \\
&\omega_i(x_i - u_i) = 0, \quad i = 1, 2, \ldots, n \\
&\mu_i \geqslant 0, \quad i = 1, 2, \ldots, n \\
&\omega_i \geqslant 0, \quad i = 1, 2, \ldots, n
\end{aligned}
$$

[4] R. Cominetti, W.F. Mascarenhas, and P.J.S. Silva, A Newton's method for the continuous quadratic knapsack problem, Math. Prog. Comp. 6 (2014), pp. 151–169.

Reformulação do Problema

Para cada $\lambda \in \mathbb{R}$ definimos

$$\bar{x}_i(\lambda) = \frac{\lambda b_i + a_i}{p_i}, \quad i = 1, 2, \ldots, n.$$

$\rightarrow$ Se $\bar{x}_i(\lambda) \leqslant \ell_i$, assumimos

$$\mu_i = \ell_i p_i - \lambda b_i - a_i, \qquad \omega_i = 0.$$

$\rightarrow$ Se $\ell_i < \bar{x}_i(\lambda) < u_i$, assumimos

$$\mu_i = 0, \qquad \omega_i = 0.$$

$\rightarrow$ Se $\bar{x}_i(\lambda) \geqslant u_i$, assumimos

$$\mu_i = 0, \qquad \omega_i = \lambda b_i + a_i - u_i p_i.$$

Reformulação do Problema

Consideramos a seguinte expressão:

$$x_i(\lambda) = \text{proj}_{[\ell_i, u_i]}\big(\bar{x}_i(\lambda)\big)$$

isto é, a projeção de

$$\bar{x}_i(\lambda) = \frac{\lambda b_i + a_i}{p_i}$$

no intervalo $[\ell_i, u_i]$, para todo $i = 1, 2, \ldots, n$.

É fácil verificar que essa expressão satisfaz as condições de KKT.

Definimos a função $x : \mathbb{R} \to \mathbb{R}^n$ dada por

$$x(\lambda) = \big(x_1(\lambda), x_2(\lambda), \ldots, x_n(\lambda)\big),$$

onde cada $x_i(\lambda)$ é dado pela projeção anterior.

É fácil ver que $x(\lambda)$ é solução do Problema (1) se, e somente se,

$$b^T x(\lambda) = c. \tag{3}$$

Reformulação do Problema

Assim, resolver o Problema (1) é equivalente a encontrar um valor real de λ que satisfaça a Equação (3).

Definimos a função $g : \mathbb{R} \to \mathbb{R}$
dada por

$$g(\lambda) := b^T x(\lambda) - c = \sum_{i=1}^{n} b_i x_i(\lambda) - c. \tag{4}$$

Aqui $x(\lambda) = \big(x_1(\lambda), x_2(\lambda), \ldots, x_n(\lambda)\big)$.

A função g possui as seguintes propriedades:

- $\to$ é contínua;
- $\to$ é linear por partes;
- $\to$ não diferenciável nos pontos de quebra

$$\frac{p_i \ell_i - a_i}{b_i} \quad \text{e} \quad \frac{p_i u_i - a_i}{b_i}.$$

Reformulação do Problema

Temos que $\lambda^* \in \mathbb{R}$ é raiz da Equação (4) se, e somente se,

$$b^T x(\lambda^*) = c.$$

Ou seja, λ^* é raiz de g se, e somente se, $x(\lambda^*)$ é solução do Problema (1).

Portanto, o problema original de minimização pode ser reformulado como

$$\begin{cases} g(\lambda) = 0, \\ \lambda \in \mathbb{R}. \end{cases}$$

A não diferenciabilidade de g torna difícil utilizar métodos que dependem da derivada para resolver o problema

$$g(\lambda) = 0.$$

Por essa razão, buscamos aproximações suaves da função g para superar essa dificuldade.

Sumário

Introdução

Reformulação do Problema
- Reformulação do Problema

Aproximações Suaves
- Aproximações Suaves

O Método Proposto
- Smoothing Gradient-Type Algorithm (SGTA)
- Complexidade

Experimentos Numéricos

Aproximações Suaves

Primeiramente, apresentamos uma reformulação do operador de projeção sobre uma caixa.

Observamos que

$$\mathsf{proj}_{[\ell,u]}(x) = \max(\ell, \min(x, u)).$$

Após algumas manipulações algébricas, obtemos

$$\mathsf{proj}_{[\ell,u]}(x) = \ell + \max\big(0, x - \ell - \max(0, x - u)\big).$$

Definindo

$$r(\lambda) = \max(0, \lambda),$$

podemos reescrever

$$x_i(\lambda) = \mathsf{proj}_{[\ell_i,u_i]}\big(\bar{x}_i(\lambda)\big) = \ell_i + r\big(\bar{x}_i(\lambda) - \ell_i - r(\bar{x}_i(\lambda) - u_i)\big).$$

Aproximações Suaves

Substituindo a expressão anterior em (4), obtemos

$$g(\lambda) = \sum_{i=1}^{n} b_i\big(\ell_i + r(\bar{x}_i(\lambda) - \ell_i - r(\bar{x}_i(\lambda) - u_i))\big) - c,$$

onde $\bar{x}_i(\lambda) = \frac{\lambda b_i + a_i}{p_i}, \qquad i = 1, 2, \ldots, n.$

Definição. Seja $\phi : \mathbb{R} \times \mathbb{R}_+ \to \mathbb{R}$ uma função suave. Dizemos que $\phi(\lambda, \tau)$ é uma aproximação suave com parâmetro τ da função

$$r(\lambda) = \max(0, \lambda),$$

se existir uma função contínua e estritamente crescente $\nu : \mathbb{R}_+ \to \mathbb{R}_+$ tal que $\nu(0) = 0$ e $|\phi(\lambda, \tau) - r(\lambda)| \leqslant \nu(\tau), \qquad \forall \lambda \in \mathbb{R},\ \tau > 0.$

A função $\phi(\lambda, \tau)$ fornece uma aproximação suave de $r(\lambda)$ que se torna cada vez mais precisa quando $\tau \to 0^+$.

Aproximações Suaves

Assumimos as seguintes propriedades:

(i) $\phi'(\lambda, \tau) : \mathbb{R} \times \mathbb{R}_+ \to [0, 1]$

(ii) $\phi'(\lambda, \tau)$ é C^1 em relação a λ

(iii) $\phi''(\lambda, \tau) > 0$ em relação a λ

(iv) $\lim_{\lambda \to -\infty} \phi(\lambda, \tau) = 0 \quad \text{e} \quad \lim_{\lambda \to +\infty} \phi(\lambda, \tau) = 1$

Observe que, pela condição (iii), a função $\phi(\lambda, \tau)$ é estritamente convexa.

Foi demonstrado que se $\phi(\lambda, \tau)$ é estritamente convexa, então

$$0 < \phi'(\lambda, \tau) < 1.$$

Aproximações Suaves

Apresentamos a seguir dois exemplos de funções de aproximação para $r(\lambda)$ que satisfazem as propriedades (i)–(iv).

Baseado no trabalho de W. Bian e X. Chen[5], consideramos:

Função de suavização baseada em rede neural

$$\phi_1(\lambda, \tau) = \tau \ln\left(1 + e^{\frac{\lambda}{\tau}}\right), \qquad \tau > 0,$$

onde $\nu(\tau) = \tau \ln 2$.

Função de suavização de ponto interior

$$\phi_2(\lambda, \tau) = \frac{\lambda + \sqrt{\lambda^2 + \tau}}{2},$$

onde $\nu(\tau) = \frac{\sqrt{\tau}}{2}$.

[5] W. Bian and X. Chen, Anderson acceleration for nonsmooth fixed point problems, SIAM J. Numer. Anal. 60(5) (2022), pp. 2565–2591.

Aproximações Suaves

Por simplicidade, escolhemos essas duas funções de aproximação porque elas são bem conhecidas na literatura.

Essas funções se ajustam naturalmente ao nosso arcabouço teórico, satisfazem as propriedades (i)–(iv) e fornecem uma forma clara e prática de ilustrar o processo de suavização. Como pode ser observado nos exemplos a seguir.

Considere o seguinte exemplo relacionado ao Problema (1):

Exemplo 1.

Considere o seguinte problema da mochila quadrática:

$$\begin{cases} \min\limits_{x} & \frac{1}{2}(x_1^2 + x_2^2) - (x_1 - x_2) \\ \textit{s.a.} & x_1 + 2x_2 = 10 \\ & 1 \leqslant x_1 \leqslant 10 \\ & 1 \leqslant x_2 \leqslant 5 \end{cases}$$

Aproximações Suaves

Para o problema do Exemplo 1, a função $g(\lambda)$ é dada por

$$g(\lambda) = r(\lambda - r(\lambda - 9)) + 2r(2\lambda - 2 - r(2\lambda - 6)) - 7.$$

Definindo $\tau = 1$ e substituindo a função $r(\cdot)$ em $g(\lambda)$ pelas funções de suavização $\phi_1(\cdot, 1)$ e $\phi_2(\cdot, 1)$, obtemos $g_{\phi_1}(\lambda)$ e $g_{\phi_2}(\lambda)$.

$$g_{\phi_1}(\lambda) = \ln\left(1 + e^{\lambda - \ln(1 + e^{\lambda - 9})}\right) + 2\ln\left(1 + e^{2\lambda - 2 - \ln(1 + e^{2\lambda - 6})}\right) - 7.$$

$$g_{\phi_2}(\lambda) = \frac{\lambda + 9 - \sqrt{(\lambda - 9)^2 + 1} + \sqrt{\left(\lambda + 9 - \sqrt{(\lambda - 9)^2 + 1}\right)^2 + 4}}{4}$$

$$+ \frac{2\lambda + 2 - \sqrt{(2\lambda - 6)^2 + 1} + \sqrt{\left(2\lambda + 2 - \sqrt{(2\lambda - 6)^2 + 1}\right)^2 + 4}}{2} - 7.$$

Aproximações Suaves

As Figuras a seguir mostram como os gráficos das funções $g_{\phi_1}(\lambda)$ e $g_{\phi_2}(\lambda)$ são próximos do gráfico da função $g(\lambda)$, respectivamente.

Figure: Gráficos das funções g e g_{ϕ_1} do Exemplo 1.

Figure: Gráficos das funções g e g_{ϕ_2} do Exemplo 1.

Suavização da Função

No que segue, substituímos a função

$$r(\lambda) = \max(0, \lambda)$$

por uma aproximação suave paramétrica $\phi(\lambda, \tau)$ na expressão

$$g(\lambda) = \sum_{i=1}^{n} b_i\big(\ell_i + r(\bar{x}_i(\lambda) - \ell_i - r(\bar{x}_i(\lambda) - u_i))\big) - c.$$

Mostramos que a função gerada é suave e aproxima $g(\lambda)$ quando $\tau > 0$ tende a zero.

Substituindo $x_i(\lambda)$ por $x_{i_\phi}(\lambda, \tau)$ na função g, com

$$x_{i_\phi}(\lambda, \tau) = \ell_i + \phi\big(\overline{x}_i(\lambda) - \ell_i - \phi(\overline{x}_i(\lambda) - u_i, \tau), \tau\big),$$

onde $\phi(\cdot, \tau)$ é uma função de aproximação de $r(\lambda)$.

Suavização da Função

Obtemos então a seguinte função suave:

$$g_\phi(\lambda,\tau) = \sum_{i=1}^{n} b_i \left(\ell_i + \phi\big(\overline{x}_i(\lambda) - \ell_i - \phi(\overline{x}_i(\lambda) - u_i, \tau), \tau\big)\right) - c.$$

Os próximos resultados mostram que $g_\phi(\lambda,\tau)$ aproxima $g(\lambda)$ quando $\tau > 0$ tende a zero, garantindo que esta é uma aproximação suave de g.

Lema 1.
Sejam $\alpha, \beta \in \mathbb{R}$ *e* $\tau > 0$. *Se* $|\alpha - \beta| \leqslant \nu(\tau)$, *então*

$$|\phi(\alpha,\tau) - \phi(\beta,\tau)| \leqslant 3\nu(\tau).$$

Lema 2.
Para todo $\lambda \in \mathbb{R}$, $\tau > 0$ *e* $i = 1, \ldots, n$, *vale*

$$|x_{i_\phi}(\lambda,\tau) - x_i(\lambda)| \leqslant 4\nu(\tau).$$

Suavização da Função

Como consequência,

$$\lim_{\tau \to 0^+} x_{i_\phi}(\lambda, \tau) = x_i(\lambda).$$

Proposição 1.

Seja $\tau > 0$. *Existe uma constante positiva* $C > 0$ *tal que, para todo* $\lambda \in \mathbb{R}$,

$$|g_\phi(\lambda, \tau) - g(\lambda)| \leqslant C \cdot \nu(\tau).$$

A proposição mostra que $g_\phi(\cdot, \tau)$ é de fato uma aproximação da função $g(\cdot)$.

Além disso, o erro de aproximação pode ser controlado pelo parâmetro τ.

Lema 3.

Para todo $\lambda \in \mathbb{R}$ *e* $\tau > 0$, *temos* $0 < g'_\phi(\lambda, \tau) < \sum_{i=1}^{n} \frac{b_i^2}{p_i}$.

Método Proposto

Antes de introduzir o método, apresentaremos uma análise teórica que justifica a escolha dos parâmetros e a formulação adotada.

O nome **Smoothing Gradient-Type Algorithm** vem da equação (5), apresentada a seguir.

Como $g_\phi(\lambda, \tau)$ é diferenciável em relação a λ, para cada τ existe uma função $F_\tau(\lambda)$ tal que

$$F'_\tau(\lambda) = g_\phi(\lambda, \tau), \qquad F''_\tau(\lambda) = g'_\phi(\lambda, \tau).$$

Pelo Lema anterior, temos $F''_\tau(\lambda) > 0$, logo F_τ é convexa.

Assim, λ^* é raiz de

$$F'_\tau(\lambda) = g_\phi(\lambda, \tau)$$

se, e somente se, λ^* é minimizador de F_τ.

O Método Proposto

Consideramos o seguinte método com regularização quadrática:

$$\lambda_{k+1} \text{ é solução de } \min_{\lambda} \left\{ F_\tau(\lambda_k) + F'_\tau(\lambda_k)(\lambda - \lambda_k) + \frac{\rho}{2}(\lambda - \lambda_k)^2 \right\}. \quad (5)$$

Observe que a função

$$F_\tau(\lambda_k) + F'_\tau(\lambda_k)(\lambda - \lambda_k) + \frac{\rho}{2}(\lambda - \lambda_k)^2$$

é quadrática em $\mathbb{R}$.

Portanto, ela possui um único minimizador e, consequentemente, o problema (5) tem solução única λ_{k+1}.

É fácil ver que

$$\lambda_{k+1} = \lambda_k - \frac{F'_\tau(\lambda_k)}{\rho} = \lambda_k - \frac{g_\Phi(\lambda_k, \tau)}{\rho}.$$

O Método Proposto

Além disso, como

$$F''_\tau(\lambda) = g'_\phi(\lambda, \tau)$$

é limitada superiormente por

$$L = \sum_{i=1}^{n} \frac{b_i^2}{p_i},$$

segue que $F'_\tau(\lambda)$ é Lipschitz com constante L.
Portanto,

$$F_\tau(\lambda) \leqslant F_\tau(\gamma) + F'_\tau(\gamma)(\lambda - \gamma) + \frac{L}{2}(\lambda - \gamma)^2.$$

Tomando $\lambda = \lambda_{k+1} = \lambda_k - \frac{F'_\tau(\lambda_k)}{\rho}, \qquad \gamma = \lambda_k$ obtemos

$$F_\tau(\lambda_{k+1}) \leqslant F_\tau(\lambda_k) + F'_\tau(\lambda_k)(\lambda_{k+1} - \lambda_k) + \frac{L}{2}(\lambda_{k+1} - \lambda_k)^2.$$

O Método Proposto

Como $F'_\tau(\lambda_k) = g_\phi(\lambda_k, \tau)$ e $g_\phi(\lambda_k, \tau) = -\rho(\lambda_{k+1} - \lambda_k)$, segue que

$$F_\tau(\lambda_{k+1}) \leqslant F_\tau(\lambda_k) - \left(\rho - \frac{L}{2}\right)(\lambda_{k+1} - \lambda_k)^2.$$

Se $\rho \geqslant L$, então

$$\frac{L}{2}(\lambda_{k+1} - \lambda_k)^2 \leqslant F_\tau(\lambda_k) - F_\tau(\lambda_{k+1}).$$

Assim, sempre que $\lambda_{k+1} \neq \lambda_k$, a sequência $\{F_\tau(\lambda_k)\}$ é decrescente.

Dessa forma, assumimos $\rho = L = \sum_{i=1}^{n} \frac{b_i^2}{p_i}$, isto é,

$$\lambda_{k+1} = \lambda_k - \frac{g_\phi(\lambda_k, \tau)}{\displaystyle\sum_{i=1}^{n} \frac{b_i^2}{p_i}}.$$

Sumário

Introdução

Reformulação do Problema
- Reformulação do Problema

Aproximações Suaves
- Aproximações Suaves

O Método Proposto
- Smoothing Gradient-Type Algorithm (SGTA)
- Complexidade

Experimentos Numéricos

Smoothing Gradient-Type Algorithm (SGTA)

Passo 0. Dado $\lambda_0 \in \mathbb{R}$, $\epsilon > 0$, $\beta \in (0,1)$ e $\tau_0 > 0$.

Passo 1. Calcular

$$\bar{\lambda}_{k+1} = \lambda_k - \frac{g_\phi(\lambda_k, \tau_k)}{\displaystyle\sum_{i=1}^{n} \frac{b_i^2}{p_i}}. \qquad (??)$$

e ir para o Passo 2.

Passo 2. Se $|g(\bar{\lambda}_{k+1})| \leqslant \epsilon$, parar. Caso contrário ir ao Passo 3.

Passo 3. Se $|g_\phi(\bar{\lambda}_{k+1}, \tau_k)| \leqslant \frac{\epsilon}{2}$, definir $\tau_k := \beta\tau_k$ e voltar ao Passo 1.

Passo 4. Se

$$|g_\phi(\bar{\lambda}_{k+1}, \tau_k)| > \frac{\epsilon}{2},$$

definir $\lambda_{k+1} = \bar{\lambda}_{k+1}$, $\tau_{k+1} = \tau_k$, $k := k+1$, e voltar ao Passo 1.

Observação

Se τ_0 é escolhido de modo que

$$\nu(\tau_0) \leqslant \frac{\epsilon}{2C},$$

então, por $|g_\phi(\lambda, \tau) - g(\lambda)| \leqslant C \cdot \nu(\tau)$, temos

$$|g(\lambda)| \leqslant |g_\phi(\lambda, \tau_0)| + C\nu(\tau_0) \leqslant |g_\phi(\lambda, \tau_0)| + \frac{\epsilon}{2}.$$

Logo,

$$|g(\lambda)| - \frac{\epsilon}{2} \leqslant |g_\phi(\lambda, \tau_0)|.$$

Assim, se $|g(\lambda)| > \epsilon$, então

$$\frac{\epsilon}{2} \leqslant |g_\phi(\lambda, \tau_0)|.$$

Portanto, τ_0 não precisa ser reduzido e

$$\tau_k = \tau_0, \qquad \forall k.$$

Sumário

Introdução

Reformulação do Problema
- Reformulação do Problema

Aproximações Suaves
- Aproximações Suaves

O Método Proposto
- Smoothing Gradient-Type Algorithm (SGTA)
- Complexidade

Experimentos Numéricos

Complexidade

O próximo lema é útil para provar que o método atinge o critério de parada estabelecido no Passo 2 em tempo finito.

Lemma 1.
Para cada k, *seja* $F_{\tau_k}(\cdot)$ *uma primitiva de* $g_\phi(\cdot, \tau_k)$.
Então, existe um índice k_0 *tal que a sequência*

$$\{F_{\tau_{k_0}}(\lambda_k)\}$$

é decrescente para todo $k \geqslant k_0$, *ou então o método para até a iteração* k_0.

Theorem 2.
Suponha que, para τ_{k_0}, *com* k_0 *dado no lema anterior, a função* $F_{\tau_{k_0}}$ *seja limitada inferiormente por* F^{low}. *Método atinge o critério de parada do Passo 2 em um número de iterações limitado superiormente por*

$$k_0 + 8L\left(F_{\tau_{k_0}}(\lambda_{k_0}) - F^{low}\right)\epsilon^{-2}.$$

Comentário sobre a Complexidade

Na literatura de otimização, métodos de primeira ordem geralmente garantem complexidade da ordem de $O(\epsilon^{-2})$ em número de iterações para obter uma solução aproximada com tolerância prescrita.

Se τ_0 for escolhido de modo que

$$v(\tau_0) \leqslant \frac{\epsilon}{2C},$$

então $k_0 = 0$.
Nesse caso, o número de iterações para atingir

$$|g(\lambda_k)| \leqslant \epsilon$$

é no máximo

$$8L\left(F_{\tau_0}(\lambda_0) - F^{low}\right)\epsilon^{-2}.$$

Assim, o algoritmo SGTA possui complexidade da ordem $O(\epsilon^{-2})$, a mesma de métodos tradicionais de primeira ordem.

Experimentos Numéricos

Comparamos a qualidade das soluções do SGTA com dois métodos de referência da literatura:

→ o algoritmo APF do trabalho de A. Alves et al[6];

→ o método tipo Newton do trabalho de Cominetti et. al.[7].

Usamos o critério de parada: $|g(\lambda)| < 10^{-10}$.
Para o SGTA utilizamos parâmetros de suavização suficientemente pequenos, de modo que o erro de suavização fosse desprezível.

Os resultados mostram que:

→ O **SGTA alcança alta precisão** nas maioria das instâncias testadas.

→ Em vários casos, o método obtém **resíduos comparáveis ou menores** que APF e Newton.

[6] A. Alves, J.O. Silva, L.C. Matioli, P.S. Santos, and S.S. Souza, An accelerated fixed-point algorithm applied to quadratic convex separable knapsack problems.

[7] R. Cominetti, W.F. Mascarenhas, and P.J.S. Silva, A Newton's method for the continuous quadratic knapsack problem.

OBRIGADO!

vitalianoamaral@ufpi.edu.br

https://vitalianoamaral.github.io

vitalianoamaral.github.io