Métodos de otimização livres de derivadas

Vitaliano S. Amaral – UFPI
Programa de Pós-graduação
em Matemática - PPGMat

III ERMAC/SC
Encontro Regional de
Matemática Aplicada e Computacional
de Santa Catarina
Florianópolis - 2026

Métodos livres de derivadas

Em muitos problemas práticos de otimização, as derivadas não estão disponíveis ou são muito caras para calcular. Nessas situações, muitos problemas podem ser tratados por métodos que não envolvem derivadas.

Assim, busca-se desenvolver métodos que:

- $\rightarrow$ utilizem apenas valores da função objetivo;
- $\rightarrow$ construam aproximações de gradiente por diferenças finitas;
- $\rightarrow$ controlem o erro dessas aproximações;
- $\rightarrow$ garantam convergência com um número reduzido de avaliações da função.

Exemplos clássicos em dimensão 1:

- $\rightarrow$ Método da bisseção;
- $\rightarrow$ Método da secante.

Esses métodos ilustram a ideia central da otimização livre de derivadas.

O método da bisseção

→ Começamos com um intervalo $[a_0, b_0]$ tal que $f(a_0)\, f(b_0) < 0$.

→ Definimos o ponto médio $x_1 = \dfrac{a_0 + b_0}{2}$.

→ Se $f(a_0)f(x_1) < 0$, então $a_1 = a_0$, $b_1 = x_1$ e $[a_0, b_0] \leftarrow [a_1, b_1]$, senão $a_1 = x_1$, $b_1 = b_0$ e $[a_0, b_0] \leftarrow [a_1, b_1]$.

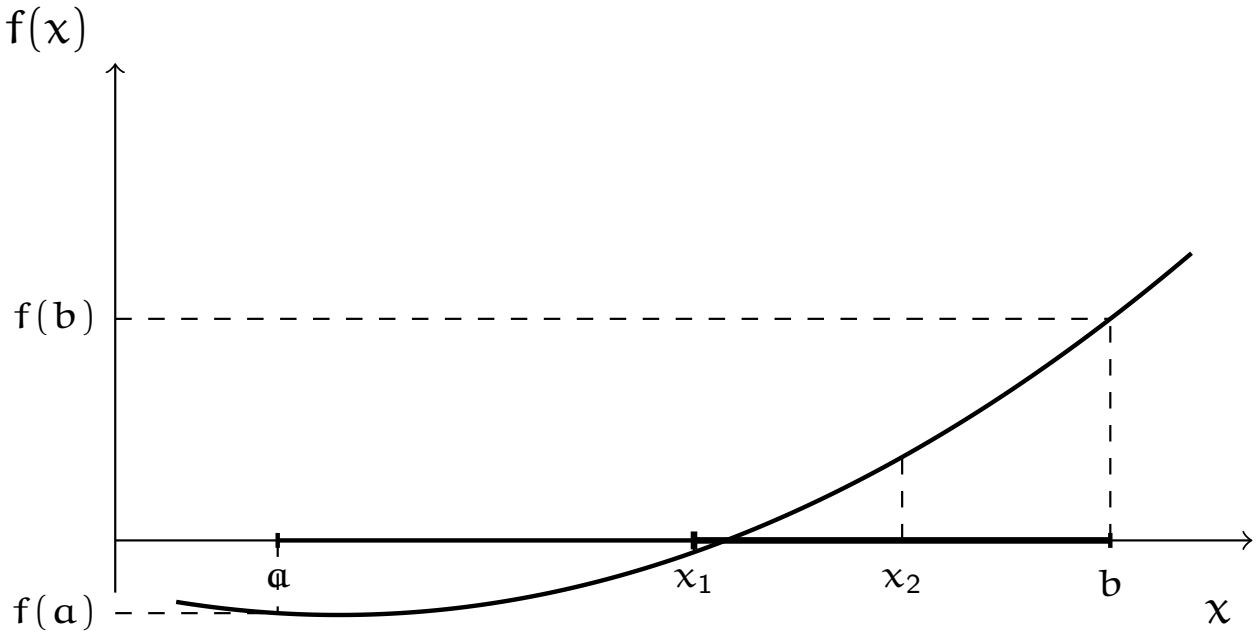

O método da secante

→ Começamos com x_0 e x_1 com $f(x_0) \neq f(x_1)$.

→ A secante por $(x_0, f(x_0))$ e $(x_1, f(x_1))$ cruza o eixo x em x_2.

→ Repetimos: a secante por $(x_1, f(x_1))$ e $(x_2, f(x_2))$ define x_3.

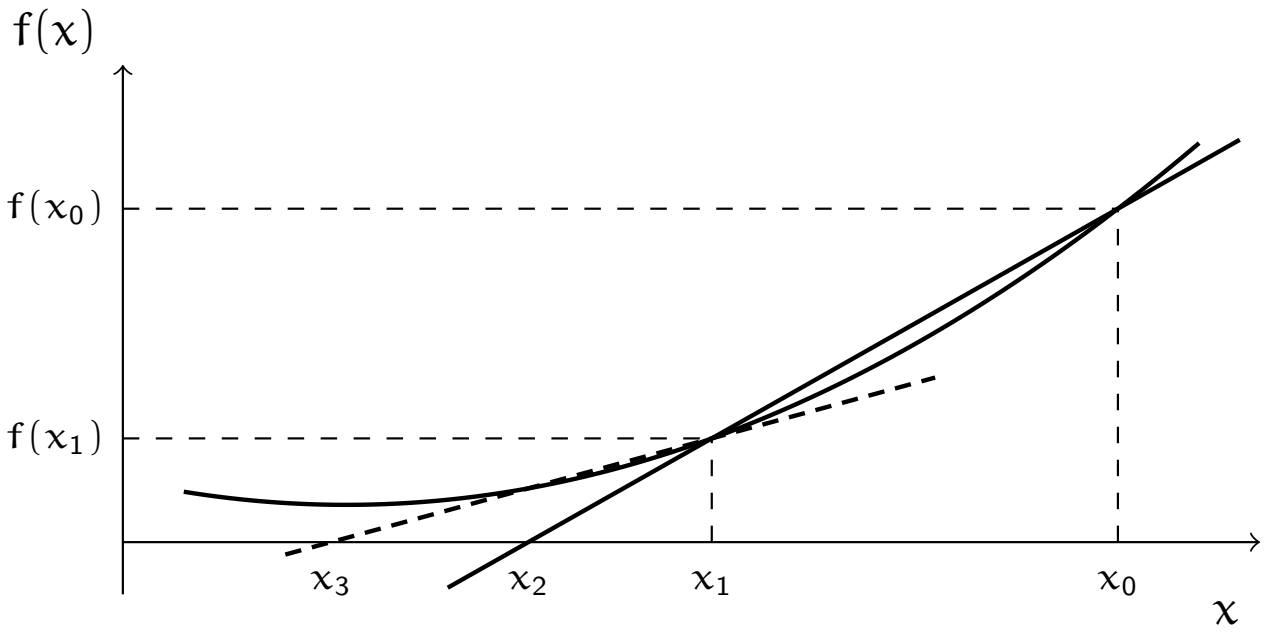

O método gera uma sequência $\{x_k\}$ satisfazendo a seguinte relação:

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k).$$

Métodos livres de derivadas

Nos últimos anos, o interesse por **métodos livres de derivadas** tem aumentado, motivado principalmente por:

- $\rightarrow$ aplicações práticas em que derivadas não estão disponíveis ou são difíceis de calcular;
- $\rightarrow$ busca por métodos com garantias teóricas de convergência e baixo custo computacional;
- $\rightarrow$ extensões de resultados clássicos da otimização suave para cenários não suaves e outros contextos.

Na literatura recente, tem surgido diversos trabalhos sobre **métodos livres de derivadas**. A seguir, destacamos alguns deles.

Métodos livres de derivadas

→ G.N. Grapiglia.(2022) - *Quadratic regularization methods with finite-difference gradient approximations.* Comput. Optim. Appl.

→ G.N. Grapiglia.(2024) - *Worst-case evaluation complexity of a derivativefree quadratic regularization method. Optim Lett.*

→ Louzeiro, M.S., Silva, G.N., Yuan, J. et al.(2025) An Adaptive Cubic Regularization Inexact-Newton Method on Riemannian Manifolds. J Sci Comput

→ Amaral, V. (2025). - *A partially derivative-free cyclic block coordinate descent method for nonseparable composite optimization.* Mathematical Modelling and Analysis.

→ V. S. Amaral, P. B. Assunção, D. R. Souza.(2026) - *A Partially Derivative-Free Proximal Method for Composite Multiobjective Optimization in the Hölder Setting.* arXiv.

Métodos livres de derivadas

No trabalho[1] foi considerado o seguinte problema:

$$\text{Minimizar } F(x) := f(x) + h(x) \text{ sujeito a } x \in \mathbb{R}^n, \tag{1}$$

onde f diferenciável e $h : \mathbb{R}^n \to \mathbb{R}$ é uma função convexa.

Neste trabalho foi proposto uma versão dos métodos BCD parcialmente livre de derivadas.

Para o desenvolvimento do método proposto, foi considerado a função

$$\varphi_f : \mathbb{R}^n \times [0, 1] \to \mathbb{R}^n \text{ onde } \lim_{\lambda \to 0} \varphi_f(x, \lambda) = \nabla f(x). \tag{2}$$

[1] V. S. Amaral. - *A partially derivative-free cyclic block coordinate descent method for nonseparable composite optimization.* Mathematical Modelling And Analysis, v. 30, p. 535-552, 2025.

Derivative-free Block Cyclic Coordinate Descent - BCDC-Dfree:

Método: Seja $x^0 \in \mathbb{R}^n$; para cada $i = 1, \ldots, q$ tome $0 \leqslant B_{(i)}(x^0) \in \mathbb{R}^{n_i \times n_i}$ simétrica; tome $\alpha \in (0,1)$, $\epsilon \in (0,1)$, $\sigma_0 \geqslant 1$ e $F_{\text{target}} \in \mathbb{R}$. Inicialize $k \leftarrow 0$.

Passo 1: Escolha $\lambda_k \in \left[0, \ \frac{\epsilon}{\sigma_k \sqrt{n}}\right]$, e considere $\varphi_f(x^k, \lambda_k)$.

Passo 2: Ponha $x^{k,0} = x^k$ e, para cada $i = 1, \ldots, q$, calcule $x^{k,i} = x^{k,i-1} + U_i s^k_{(i)}$, onde $s^k_{(i)} \in \mathbb{R}^{n_i}$ é solução de

$$\min_{s \in \mathbb{R}^{n_i}} \langle U_i^T \varphi_f(x^{k,i-1}, \lambda_k), s\rangle + \frac{1}{2}\langle B_{(i)}(x^{k,i-1})s, s\rangle + h(x^{k,i-1} + U_i s) - h(x^{k,i-1}) + \frac{\sigma_k}{2}\|s\|^2.$$

Passo 3: Se $\left\| \sum_{i=1}^q U_i s^k_{(i)} \right\|_\infty < \frac{\epsilon}{\sigma_k}$ ou $F(x^{k,q}) \leqslant F_{\text{target}}$, **pare e declare** $x^{k,q}$ como uma solução aceitável. Caso contrário, ir ao Passo 4.

Passo 4: Se

$$F(x^{k,q}) \leqslant F(x^k) - \frac{\alpha}{\sigma_k}\epsilon^2,$$

defina $x^{k+1} = x^{k,q}$ e $\sigma_{k+1} = \sigma_k$, escolha $0 \leqslant B_{(i)}(x^{k+1}) \in \mathbb{R}^{n_i \times n_i}$ simétrica, $k \leftarrow k+1$ e ir ao Passo 1. Caso contrário, defina $\sigma_k \leftarrow 2\sigma_k$ e ir ao Passo 1.

Boa definição

Para garantir a boa definição do método foi considerado que:

Assumption 1.

Existem $L, M \in (0, +\infty)$ *e* $\beta \in (0, 1]$ *tais que para todo* $x, y \in \mathbb{R}^n$

$$f(y) \leqslant f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2}\|y - x\|^2 + \frac{M}{\beta + 1}\|y - x\|^{\beta+1} \tag{3}$$

e

$$\|\nabla f(x) - \varphi_f(x, \lambda)\| \leqslant \frac{\sqrt{n}L}{2}\lambda + \frac{\sqrt{n}M}{\beta + 1}\lambda^{\beta} \tag{4}$$

A Suposição 1 é não restritiva.

Boa definição

Pois se $f := g_1 + g_2$, onde ∇g_1 L-Lipschitz e ∇g_2 M-Hölder com expoente β e alem disso φ_f for uma das fierenças finitas:

- $\varphi_f(x, \lambda) = \left[\dfrac{f(x + \lambda e_1) - f(x)}{\lambda}, \cdots, \dfrac{f(x + \lambda e_n) - f(x)}{\lambda}\right].$
- $\varphi_f(x, \lambda) = \left[\dfrac{f(x) - f(x - \lambda e_1)}{\lambda}, \cdots, \dfrac{f(x) - f(x - \lambda e_n)}{\lambda}\right].$
- $\varphi_f(x, \lambda) = \left[\dfrac{f(x + \lambda e_1) - f(x - \lambda e_1)}{2\lambda}, \cdots, \dfrac{f(x + \lambda e_n) - f(x - \lambda e_n)}{2\lambda}\right],$

então (3) e (4) são válidas.

Boa definição

De fato:

$$\rightarrow\ g_1(y) \leqslant g_1(x) + \langle \nabla g_1(x), y - x\rangle + \frac{L}{2}\|y - x\|^2\ \forall\, x, y \in \mathbb{R}^n$$

$$\rightarrow\ g_2(y) \leqslant g_2(x) + \langle \nabla g_2(x), y - x\rangle + \frac{M}{\beta + 1}\|y - x\|^{\beta+1}\ \forall\, x, y \in \mathbb{R}^n.$$

Somando as duas expressões obtemos (3).

$$\rightarrow\ \|\nabla g_1(x) - \varphi_{g_1}(x, \lambda)\| \leqslant \frac{\sqrt{n}L}{2}\lambda.$$

$$\rightarrow\ \|\nabla g_2(x) - \varphi_{g_2}(x, \lambda)\| \leqslant \frac{\sqrt{n}M}{\beta + 1}\lambda^{\beta}.$$

Somando as duas expressões e usando deslgualdade trianfular obtems (4).

Boa definição

Além das suposições anterior foi considerado que: existe $\overline{B} \geqslant 1$ tal que $\|B_{(i)}(x^{k,i-1})\| \leqslant \overline{B}$ para todos os $i \in \{1, \ldots, q\}$ e k.

Assim, provamos que se

$$\|s^k\|_\infty \geqslant \frac{\epsilon}{\sigma_k} \text{ e } \sigma_k \geqslant \left[\frac{2L + q\overline{B}}{(1-\alpha)} + \frac{2q(Mn^{\frac{1-\beta}{2}} + M)}{(\beta+1)(1-\alpha)}\epsilon^{\beta-1}\right]^{\frac{1}{\beta}}$$

então

$$F(x^{k,q}) \leqslant F(x^k) - \alpha\frac{\sigma_k}{2}\|s^k\|_\infty^2$$

e

$$F(x^{k,q}) \leqslant F(x^k) - \frac{\alpha}{\sigma_k}\epsilon^2.$$

Garantindo assim a boa definição do método.

Complexidade

→ Números de Iterações é limitado superiormente por:

$$\frac{c\big(F(x^0) - F_{target}\big)}{\alpha}\epsilon^{-\frac{\beta+1}{\beta}}.$$

→ Número de avaliações de f e seus subdiferenciais é limitado superiormente por:

$$\frac{c\big(F(x^0) - F_{target}\big)}{\alpha}\epsilon^{-\frac{\beta+1}{\beta}} + \log_2\left(\frac{\sigma_{max}}{\sigma_{min}}\right).$$

com

$$\sigma_{max} = 2\epsilon^{\frac{\beta-1}{\beta}} \max\left\{\sigma_{min}, \left[\frac{2L + q\overline{B}}{(1-\alpha)} + \frac{2q(Mn^{\frac{1-\beta}{2}} + M)}{(\beta+1)(1-\alpha)}\right]^{\frac{1}{\beta}}\right\}.$$

Testes Numéricos

Nos testes foi considerado o problema de mínimos quadrados penalizado por uma norma L_p:

$$\min F(x) = \frac{1}{2}\|A(x) - b\|_2^2 + \frac{\lambda}{p}\|\Phi(x)\|_p^p, \tag{5}$$

com $1 < p < 2$, A diferenciável e Φ linear.

Consideramos $B_{(i)} \equiv 0$, $n = 10$, $\alpha = 0,5$, $\epsilon = 5 \times 10^{-5}$, $\quad F_{\text{target}} = 0,5$ e a função $\varphi_f : \mathbb{R}^{10} \times \mathbb{R} \to \mathbb{R}^{10}$ definida por

$$\varphi_f(x, \lambda) = \left[\frac{f(x + \lambda e_1) - f(x)}{\lambda}, \cdots, \frac{f(x + \lambda e_{10}) - f(x)}{\lambda}\right].$$

Testes Numéricos

Teste 1: $A \in \mathbb{R}^{10\times 10}$ e $b \in \mathbb{R}^{10}$ são fixados. Utilizamos $p = 3/2$, $f(x) = 0.5\|Ax - b\|^2 + 5 \times 10^{-5} \sum_{i=1}^{10} |x_i|^{3/2}$, $h(x) = 0$ e $x^0 = 0 \in \mathbb{R}^{10}$.

λ_k	N. Blocos	σ_0	N. Iterações	Approx. F^*
$\frac{\epsilon}{\sigma_k\sqrt{10}}$	10	1	10	0.4731
	10	500	40	0.3021
	10	1000	83	0.3003

Teste 2: $A \in \mathbb{R}^{10\times 10}$ e $b \in \mathbb{R}^{10}$ aleatórios, Φ é a função identidade e h nula. Foram avaliadas 100 instâncias, todas com x^0 aleatório.

Blocos	σ_0	Iterações Médias	Média-F
10	1	11.55	0.4329
1	1	17.56	0.4682

Testes Numéricos

Teste 3: σ_0 foi sorteado no intervalo $[1, 1000]$, mantendo os demais dados inalterados.

Blocos	Iterações Médias	Média-F
10	805.45	0.4988
1	809.02	0.4988

Teste 3: A em (5) é não linear, definido por

$$A(x) = (A_1(x), \ldots, A_n(x)), \quad A_i(x) = \frac{x_i}{1 + x_{i+1}^2}, \; i = 1, \ldots, n-1,$$

com $x_{n+1} = x_1$. Tomamos $\Phi(x) = Bx$, com $B \in \mathbb{R}^{m \times n}$ aleatório e b também aleatório. Foram avaliadas 100 instâncias, todas com x^0 aleatório e σ_0 sorteado em $[1, 100]$.

Blocos	Iterações Médias	Média-F
10	648.96	0.5008
1	664.61	0.5008

Métodos livres de derivadas em otimização multiobjetivo

Recentemente[2], estudamos o seguinte problema de otimização:

$$\min_{x \in \mathbb{R}^n} F(x), \tag{6}$$

onde $F : \mathbb{R}^n \to \mathbb{R}^m$ com componentes dados por

$$F_j = f_j + h_j, \quad j \in \mathcal{N} = \{1, \ldots, m\}.$$

Assumimos $f_j : \mathbb{R}^n \to \mathbb{R}$ diferenciável e $h_j : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ convexa.

Um caso particular do Problema (6) é obtido quando h_j é a função indicadora de um conjunto convexo $C \subset \mathbb{R}^n$. Nesse caso, o Problema (6) torna-se o problema multiobjetivo com restrições:

$$\min_{x \in C} \big(f_1(x), \cdots, f_m(x)\big).$$

[2] V. S. Amaral, P. B. Assunção, D. R. Souza. A Partially Derivative-Free Proximal Method for Composite Multiobjective Optimization in the Hölder Setting.

Métodos livres de derivadas em otimização multiobjetivo

Recentemente, problemas multiobjetivo compostos têm sido abordados em diversos trabalhos, por exemplo:

→ Gradiente proximal: proposto por Fukuda et al.[3].

→ Um método de gradiente proximal com uma busca linear explícita: proposto por Bello-Cruz et al.[4]

→ Gradiente condicional generalizado: proposto por Assunção et al.[5]

[3] Tanabe, H., Fukuda, E.H., Yamashita, N.: Proximal gradient methods for multiobjective optimization and their applications. Comp. Optim. Appl.

[4] Bello-Cruz, Y., Melo, J.G., Prudente, L.F., Serra, R.V.G.: A proximal gradient method with an explicit line search for multiobjective optimization. Comp. Optim. Appl.

[5] Assunção, P.B., Ferreira, O.P., Prudente, L.F.: A generalized conditional gradient method for multiobjective composite optimization problems. Optimization

→ x^* é um ponto Pareto ótimo para o Problema (1) se não existe x tal que

$$G(x) \leqslant G(x^*) \quad \text{e} \quad G(x) \neq G(x^*),$$

onde a desigualdade $\leqslant$ entre vetores deve ser entendida no sentido componente a componente.

Isto é, não é possível melhorar um objetivo sem piorar o outro.

→ x^* é um ponto Pareto crítico se existe $\gamma \in \mathbb{R}^m$ com $\gamma \geqslant 0$ e $\sum_{j=1}^{m} \gamma_j = 1$, tal que

$$0 \in \sum_{j=1}^{m} \gamma_j \big(\nabla f_j(x^*) + \partial h_j(x^*)\big). \tag{7}$$

Exemplo ilustrativo

Exemplo: $\min_{x \in \mathbb{R}^n} \left(F_1(x) = \frac{1}{2}\|x - P\|^2,\ F_2(x) = \frac{1}{2}\|x - Q\|^2 \right), \quad P, Q \in \mathbb{R}^n$

$\rightarrow$ Problema para minimizar as distâncias até P e Q simultaneamente.

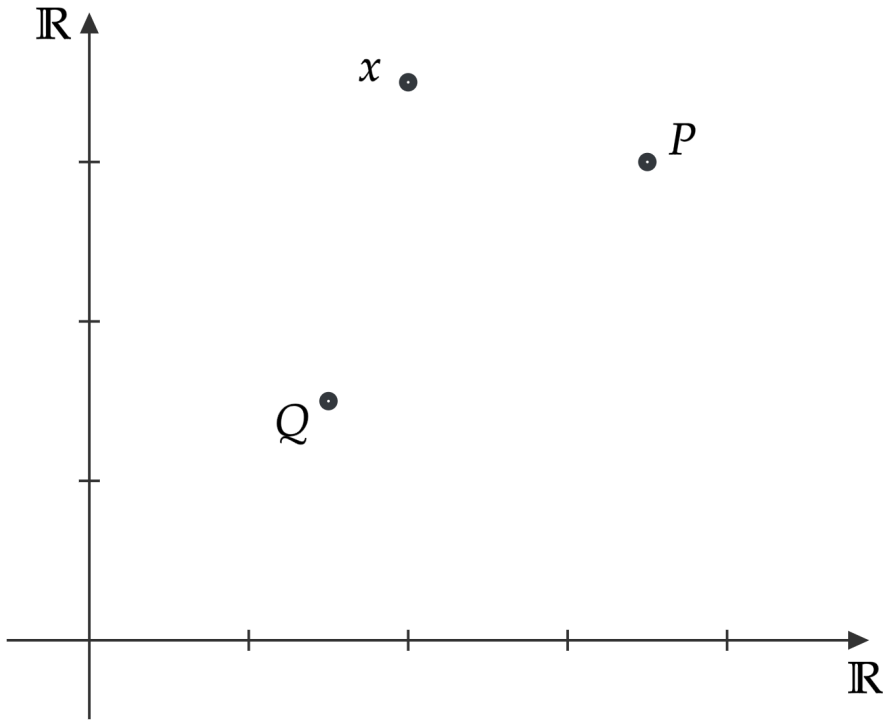

Soluções no segmento de reta que liga P e Q

Exemplo ilustrativo

Exemplo: $\min_{x \in \mathbb{R}^n} \left(F_1(x) = \frac{1}{2}\|x - P\|^2,\ F_2(x) = \frac{1}{2}\|x - Q\|^2 \right), \quad P, Q \in \mathbb{R}^n$

→ Problema para minimizar as distâncias até P e Q simultaneamente.

- As soluções pertencem ao segmento de reta que conecta P e Q.

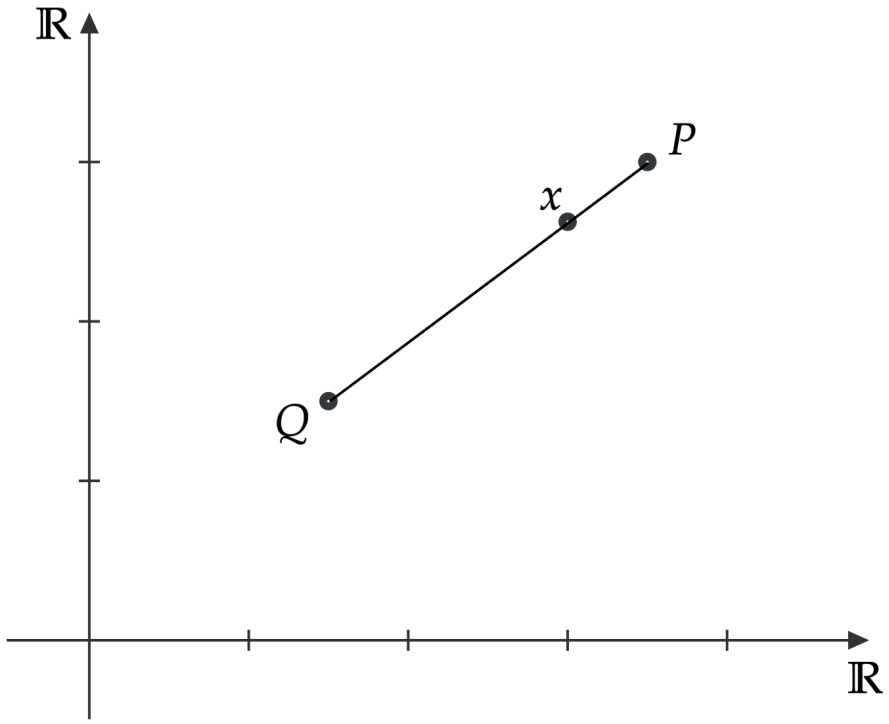

Soluções no segmento de reta que liga P e Q

Exemplo ilustrativo

Exemplo: $\min_{x \in \mathbb{R}^n} \left(F_1(x) = \frac{1}{2}\|x - P\|^2,\ F_2(x) = \frac{1}{2}\|x - Q\|^2 \right), \quad P, Q \in \mathbb{R}^n$

→ Problema para minimizar as distâncias até P e Q simultaneamente.

- As soluções pertencem ao segmento de reta que conecta P e Q.
- Neste segmento de reta, não é possível se aproximar de Q sem se afastar de P.
- Estes pontos no segmento de reta são de Pareto.

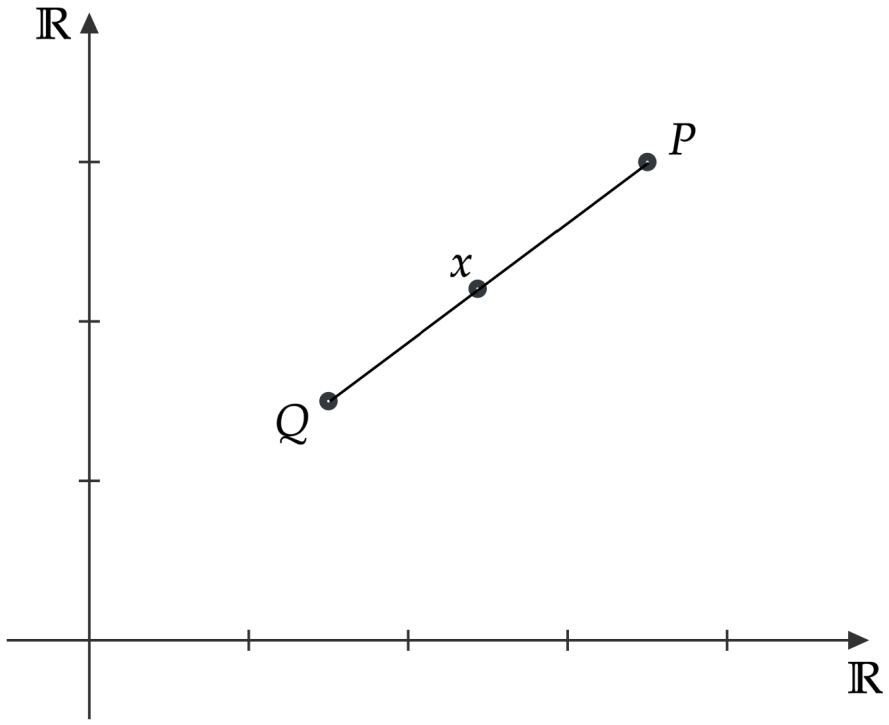

Soluções no segmento de reta que liga P e Q

Método proximal parcialmente livre de derivadas - PDFPM

Propomos um Método Proximal Parcialmente Livre de Derivadas - PDFPM para resolver o Problema (6), em que, dado x^k, o PDFPM encontra um novo ponto x^{k+1} tal que

$$F(x^{k+1}) < F(x^k).$$

Svaiter et al.(2000)[6] parecem ter sido pioneiros nessa abordagem para otimização multiobjetivo.

Em cada interação, o método PDFPM minimiza o seguinte modelo:

$$\max_{j\in\mathcal{J}} \left[\langle g_{f_j}(x^k,\lambda_k)+\frac{1}{2}B_j^k(x-x^k),\, x-x^k\rangle+h_j(x)-h_j(x^k)\right]+\frac{\sigma_k}{2}\|x-x^k\|^2,$$

onde $g_{f_j} : \mathbb{R}^n \times [0,1] \to \mathbb{R}^n$ é uma aproximação de ∇f_j e $B_j^k \in \mathbb{R}^{n\times n}$ simétrica semidefinida positiva(SPSD).

[6] J. Fliege and B. F. Svaiter, *Steepest descent methods for multicriteria optimization*, Math. Methods Oper. Res. 51(3), 479–494 (2000).

Método proximal parcialmente livre de derivadas - PDFPM

O método PDFPM

Algoritmo: Sejam $x^0 \in \mathbb{R}^n$, $\alpha, \epsilon \in (0,1)$, $\sigma_0 \geqslant 1$ e uma matriz SPSD $B_j^0 \in \mathbb{R}^{n\times n}$.

Passo 1. Para $\lambda_k \in \left(0, \frac{\epsilon}{\sigma_k\sqrt{n}}\right]$, calcule $g_{f_j}(x^k, \lambda_k)$ para todo $j \in \mathcal{N}$.

Passo 2. Encontre $\bar{x}^k \in \mathbb{R}^n$ a solução do seguinte subproblema:

$$\min_{x\in\mathbb{R}^n} \max_{j\in\mathcal{J}} \left[\langle g_{f_j}(x^k,\lambda_k)+\tfrac{1}{2}B_j^k(x-x^k),\, x-x^k\rangle+h_j(x)-h_j(x^k)\right]+\tfrac{\sigma_k}{2}\|x-x^k\|^2.$$

Passo 3. Se $\sigma_k\|\bar{x}^k - x^k\| < \epsilon$, pare. Caso contrário, vá para o ***Passo 4***.

Passo 4. Se

$$F_j(\bar{x}^k) \leqslant F_j(x^k) - \frac{\alpha\epsilon^2}{2\sigma_k}, \qquad \forall\, j \in \mathcal{N}, \tag{8}$$

defina $x^{k+1} := \bar{x}^k$, $\sigma_{k+1} := \sigma_k$, para cada j escolha uma SPSD $B_j^{k+1} \in \mathbb{R}^{n\times n}$, $k \leftarrow k+1$, e vá para o ***Passo 1***. Caso contrário, $\sigma_k \leftarrow 2\sigma_k$ e vá para o ***Passo 1***.

Boa definição

Para garantir que o PDFPM esteja bem definido, assumimos as seguintes suposições.

Suposição 1. Existe um número real positivo $\overline{B}$ tal que

$$\|B_j^k\| \leqslant \overline{B}, \quad \forall\, k \in \mathbb{N} \text{ e } j \in \mathcal{N}.$$

Suposição 2. Para cada $j \in \mathcal{N}$, existem números reais positivos L_j, M_j e $\beta_j \in (0, 1]$ tais que as seguintes condições são satisfeitas.

$$\rightarrow\ f_j(y) \leqslant f_j(x) + \langle \nabla f_j(x), y - x\rangle + \frac{L_j}{2}\|y - x\|^2 + \frac{M_j}{\beta_j + 1}\|y - x\|^{\beta_j + 1}.$$

$$\rightarrow\ \|\nabla f_j(x) - g_{f_j}(x, \lambda)\| \leqslant \lambda \frac{\sqrt{n} L_j}{2} + \sqrt{n}\frac{M_j}{\beta_j + 1}\lambda^{\beta_j}.$$

A Suposição 2 é válida quando algumas funções f_j têm gradientes Lipschitz, outras têm gradientes Hölder e g_{f_j} é obtida usando diferenças finitas.

Boa definição

Para garantir que o PDFPM esteja bem definido, assumimos as seguintes suposições.

Suposição 1. Existe um número real positivo $\overline{B}$ tal que

$$\|B_j^k\| \leqslant \overline{B}, \quad \forall\, k \in \mathbb{N} \text{ e } j \in \mathcal{N}.$$

Suposição 2. Para cada $j \in \mathcal{N}$, existem números reais positivos L_j, M_j e $\beta_j \in (0, 1]$ tais que as seguintes condições são satisfeitas.

$$\rightarrow\ f_j(y) \leqslant f_j(x) + \langle \nabla f_j(x), y - x\rangle + \frac{L_j}{2}\|y - x\|^2 + \frac{M_j}{\beta_j + 1}\|y - x\|^{\beta_j + 1}.$$

$$\rightarrow\ \|\nabla f_j(x) - g_{f_j}(x, \lambda)\| \leqslant \lambda\frac{\sqrt{n}L_j}{2} + \sqrt{n}\frac{M_j}{\beta_j + 1}\lambda^{\beta_j}.$$

A Suposição 2 é válida quando algumas funções f_j têm gradientes Lipschitz, outras têm gradientes Hölder e g_{f_j} é obtida usando diferenças finitas.

Boa definição

Para garantir que o PDFPM esteja bem definido, assumimos as seguintes suposições.

Suposição 1. Existe um número real positivo $\overline{B}$ tal que

$$\|B_j^k\| \leqslant \overline{B}, \quad \forall\, k \in \mathbb{N} \text{ e } j \in \mathcal{N}.$$

Suposição 2. Para cada $j \in \mathcal{N}$, existem números reais positivos L_j, M_j e $\beta_j \in (0, 1]$ tais que as seguintes condições são satisfeitas.

$$\rightarrow\ f_j(y) \leqslant f_j(x) + \langle \nabla f_j(x), y - x\rangle + \frac{L_j}{2}\|y - x\|^2 + \frac{M_j}{\beta_j + 1}\|y - x\|^{\beta_j + 1}.$$

$$\rightarrow\ \|\nabla f_j(x) - g_{f_j}(x, \lambda)\| \leqslant \lambda\frac{\sqrt{n}L_j}{2} + \sqrt{n}\frac{M_j}{\beta_j + 1}\lambda^{\beta_j}.$$

A Suposição 2 é válida quando algumas funções f_j têm gradientes Lipschitz, outras têm gradientes Hölder e g_{f_j} é obtida usando diferenças finitas.

Boa definição

Para garantir que o PDFPM esteja bem definido, assumimos as seguintes suposições.

Suposição 1. Existe um número real positivo $\overline{B}$ tal que

$$\|B_j^k\| \leqslant \overline{B}, \quad \forall\, k \in \mathbb{N} \text{ e } j \in \mathcal{N}.$$

Suposição 2. Para cada $j \in \mathcal{N}$, existem números reais positivos L_j, M_j e $\beta_j \in (0, 1]$ tais que as seguintes condições são satisfeitas.

$$\rightarrow\ f_j(y) \leqslant f_j(x) + \langle \nabla f_j(x), y - x\rangle + \frac{L_j}{2}\|y - x\|^2 + \frac{M_j}{\beta_j + 1}\|y - x\|^{\beta_j + 1}.$$

$$\rightarrow\ \|\nabla f_j(x) - g_{f_j}(x, \lambda)\| \leqslant \lambda \frac{\sqrt{n} L_j}{2} + \sqrt{n}\frac{M_j}{\beta_j + 1}\lambda^{\beta_j}.$$

A Suposição 2 é válida quando algumas funções f_j têm gradientes Lipschitz, outras têm gradientes Hölder e g_{f_j} é obtida usando diferenças finitas.

Boa definição

O resultado a seguir mostra que o **Passo 4** do PDFPM está bem definida.

Teorema: Seja $\bar{x}^k$ o ponto obtido na **Etapa 2** do PDFPM. Suponha que as Suposições 1 e 2 sejam válidas.
Se

$$\sigma_k \|\bar{x}^k - x^k\| \geqslant \epsilon \tag{9}$$

e

$$\sigma_k \geqslant \max_{j \in \mathcal{J}} \left[\frac{5L_j + \overline{B}}{1-\alpha} + \frac{2n^{\frac{1-\beta_j}{2}} M_j + 2M_j}{(\beta_j + 1)(1-\alpha)} \epsilon^{\beta_j - 1} \right]^{\frac{1}{\beta_j}}, \tag{10}$$

então

$$F_j(\bar{x}^k) \leqslant F_j(x^k) - \frac{\alpha \epsilon^2}{2\sigma_k}, \qquad \forall j \in \mathcal{N}. \tag{11}$$

Em outras palavras, existe um σ_k que garante uma redução em F no **Passo 4**.

Assim, garantimos que o método PDFPM é bem definido.

Complexidade

Dado um alvo $\bar{F} < F(x^0)$, provamos que o número máximo de iterações para as quais

$$F(x^{k+1}) > \bar{F} \quad \text{e} \quad \sigma_k \|x^{k+1} - x^k\| \geqslant \epsilon, \tag{12}$$

é dado por

$$\max_{j \in \mathcal{J}} \left\{ F_j(x^0) - \bar{F}_j \right\} \frac{2c}{\alpha} \, \epsilon^{-\frac{\beta+1}{\beta}}, \tag{13}$$

onde

$$c = 2 \max_{j \in \mathcal{J}} \left[\frac{2L_j + \overline{B}}{1-\alpha} + \frac{2n^{\frac{1-\beta_j}{2}} M_j + 2M_j}{(\beta_j + 1)(1-\alpha)} \right]^{\frac{1}{\beta_j}}$$

e $\beta = \min\{\beta_j : j \in \mathcal{J}\}$.

É importante observar que, quando β se aproxima de zero, o número de iterações pode aumentar.

Em outras palavras, a complexidade piora quando β se aproxima de zero.

Resultados Numéricos

Os experimentos numéricos foram realizados em `Julia`.

→ Consideramos **problemas de otimização compostos** da forma

$$\min_{x \in \mathbb{R}^n} \big(f_1(x) + h_1(x), \ \ldots, \ f_m(x) + h_m(x) \big).$$

- $f_j : \mathbb{R}^n \to \mathbb{R}$ é uma função diferenciável.
- h_j é uma função convexa definida por $h_j(x) := \max_{z \in \mathcal{Z}_j} \langle x, z \rangle$.
- O conjunto de incerteza $\mathcal{Z}_j$ é dado por $\mathcal{Z}_j = \{z \in \mathbb{R}^n \mid A_j z \leqslant \delta e\}$, onde $e = (1, \ldots, 1)^\top$, $\delta \geqslant 0$, e

$$A_j := \begin{bmatrix} \tilde{A}_j \\ -\tilde{A}_j \end{bmatrix}, \quad \tilde{A}_j \in \mathbb{R}^{n \times n} \text{ é não singular.}$$

Observação: Aqui, h_j representa um caso particular de problema composto, conhecido como otimização robusta.

Comparação com Métodos Existentes

Para avaliar o desempenho do algoritmo proposto, comparamos com métodos existentes para **otimização multiobjetivo**.

- → **PDFPM**: o **Método Proximal Parcialmente Livre de Derivadas** proposto.
- → **ProxGrad**: um **método do gradiente proximal** proposto por Fukuda et al. (2019).
- → **CondG**: um **método do gradiente condicional** introduzido por Assunção et al. (2023).

Esses métodos são projetados para problemas multiobjetivo compostos, sendo, portanto, comparações naturais.

Testes Numéricos

Para ilustrar a aplicabilidade do algoritmo proposto, apresentamos os dois seguintes novos problemas-teste.

→ **AAS1:** $\min\limits_{x\in\mathbb{R}^2} \big(f_1(x), f_2(x)\big)$ onde f_1 e f_2 são dados por

$$f_1(x) = \tfrac{1}{2}\|Ax - b\|_2^2, \quad f_2(x) = \tfrac{\mu}{p}\|Dx\|_p^p, \text{ com } \mu = 0.9 \text{ e } p = 1.003.$$

Neste caso, f_1 *possui gradiente* ***Lipschitz contínuo****, enquanto* f_2 *possui gradiente* ***Hölder contínuo****.*

→ **AAS2:** $\min\limits_{x\in\mathbb{R}^2} \big(f_1(x), f_2(x)\big)$ onde f_1 e f_2 são dados por

$$f_1(x) = \tfrac{\mu_1}{p_1}\|D_1(x-c_1)\|_{p_1}^{p_1}, \quad f_2(x) = \tfrac{\mu_2}{p_2}\|D_2(x-c_2)\|_{p_2}^{p_2}, \text{ com } \mu_1 = 1.2,$$

$$\mu_2 = 0.8, \quad p_1 = 1.003 \text{ e } p_2 = 1.002.$$

Neste caso, tanto f_1 *quanto* f_2 *possuem gradientes* ***Hölder contínuos****.*

Frentes de Pareto: AAS1

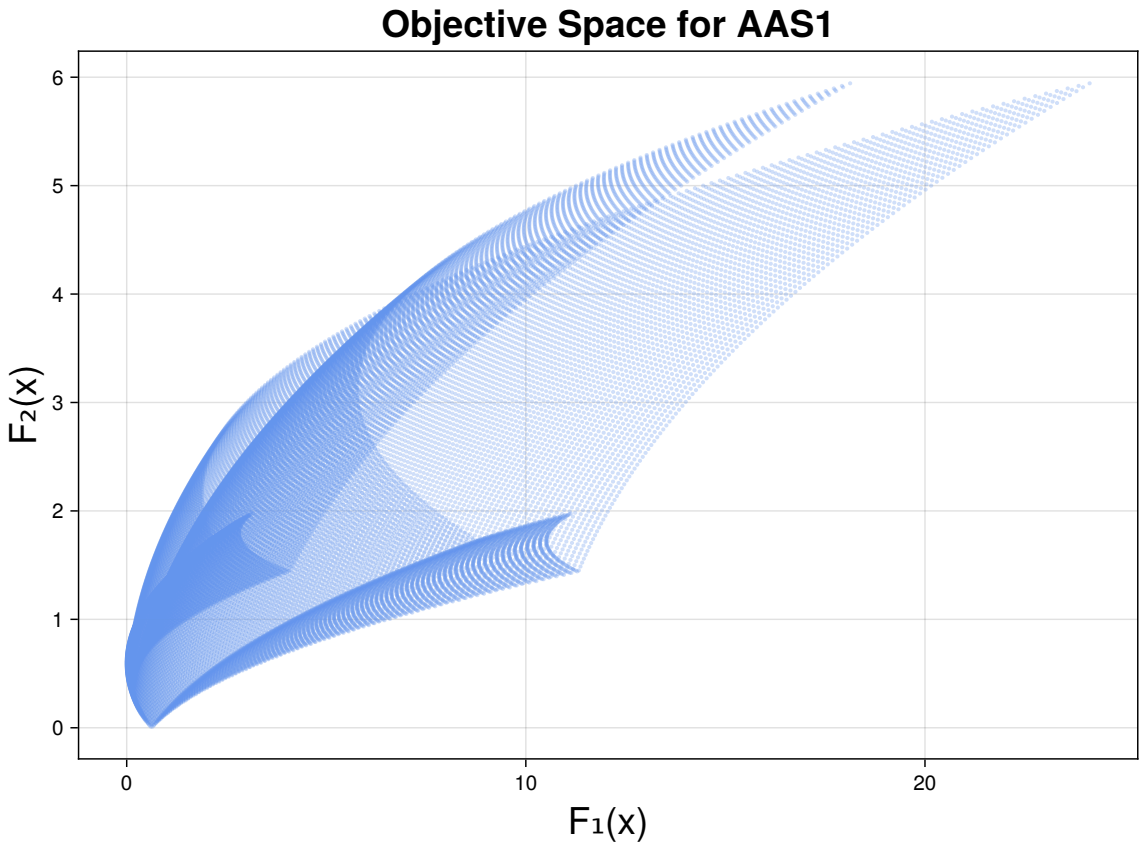

→ **Espaço objetivo:** visão global do problema biobjetivo.

Frentes de Pareto: AAS1

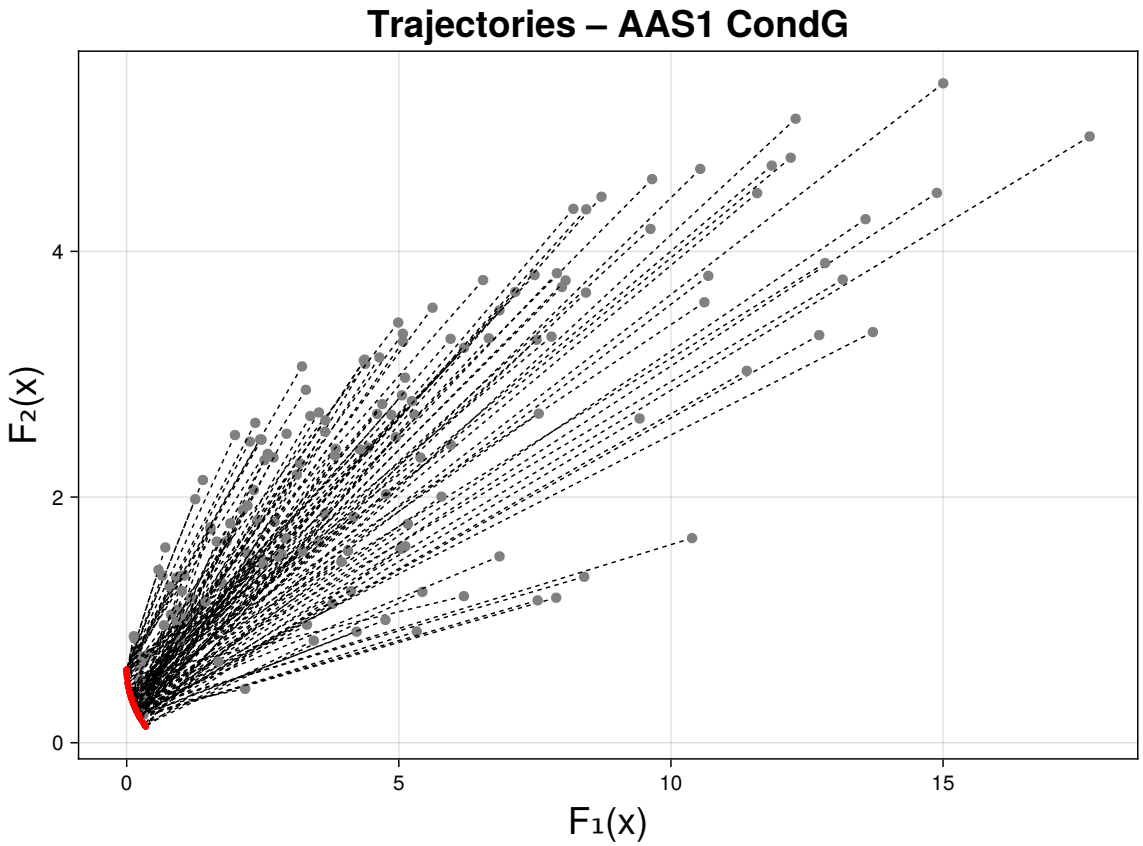

→ **CondG:** as trajetórias e a aproximação da fronteira de Pareto.

Frentes de Pareto: AAS1

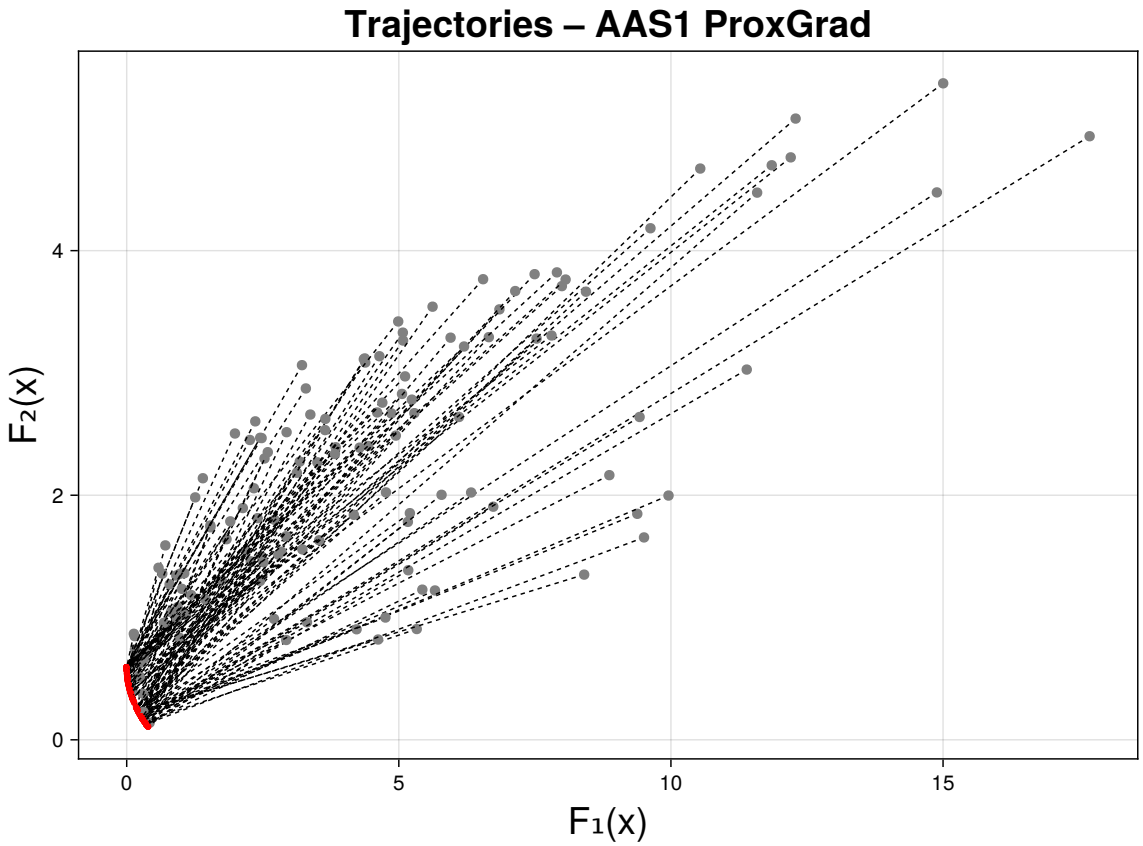

→ **ProxGrad:** as trajetórias e a aproximação da fronteira de Pareto.

Frentes de Pareto: AAS1

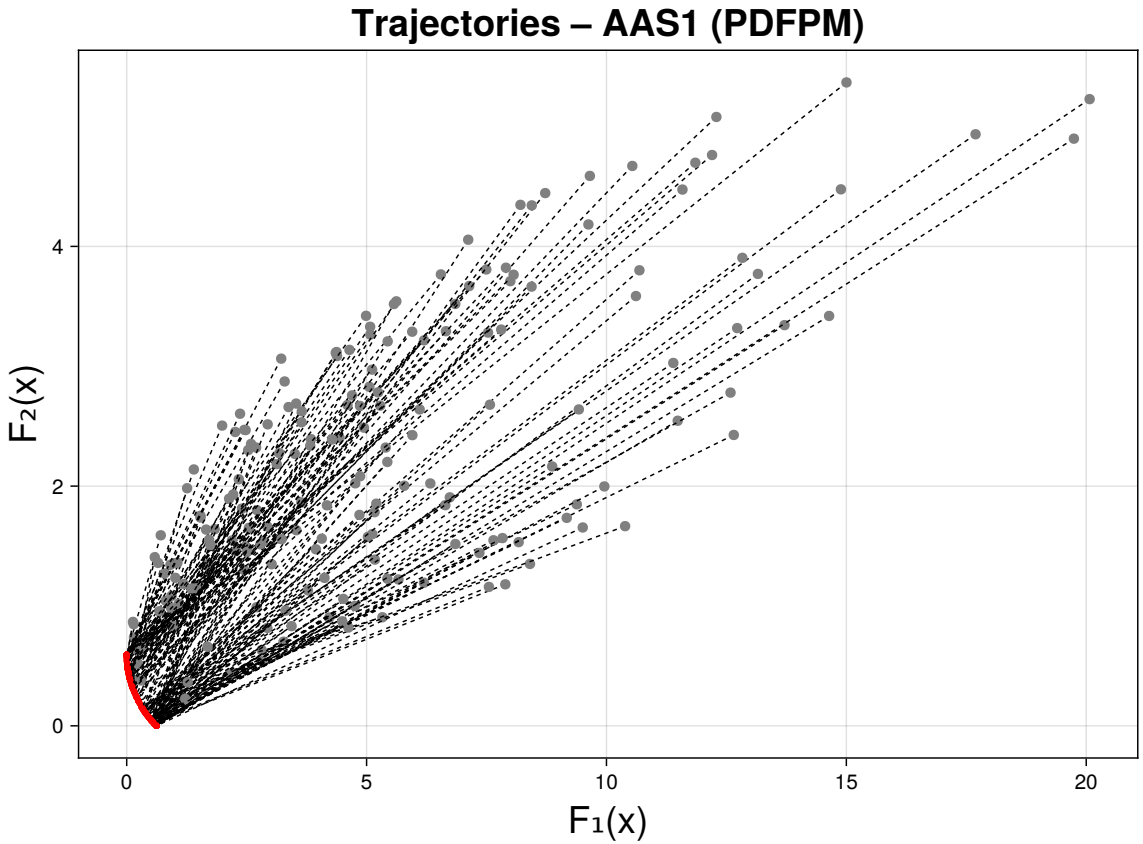

→ **PDFPM:** as trajetórias e a aproximação da fronteira de Pareto.

Podemos observar que nosso método obteve uma parte mais significativa da fronteira de Pareto.

Frentes de Pareto: AAS2 (Caso totalmente Hölder)

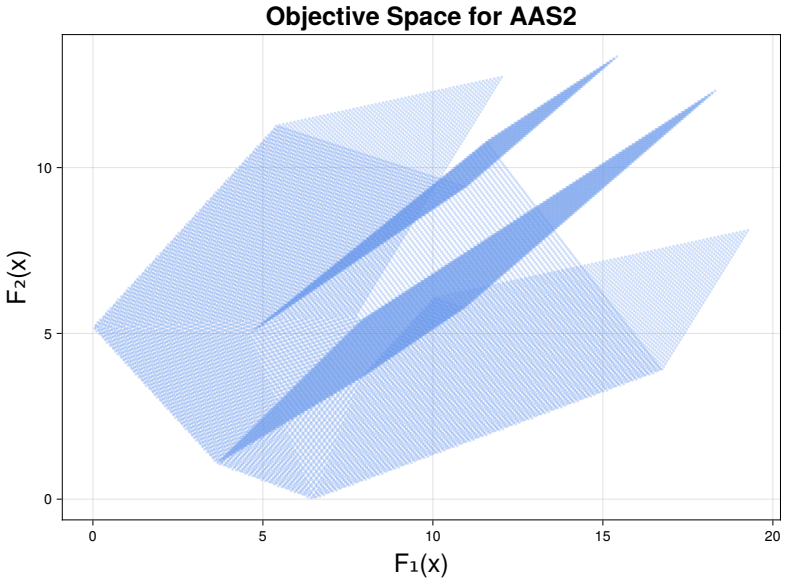

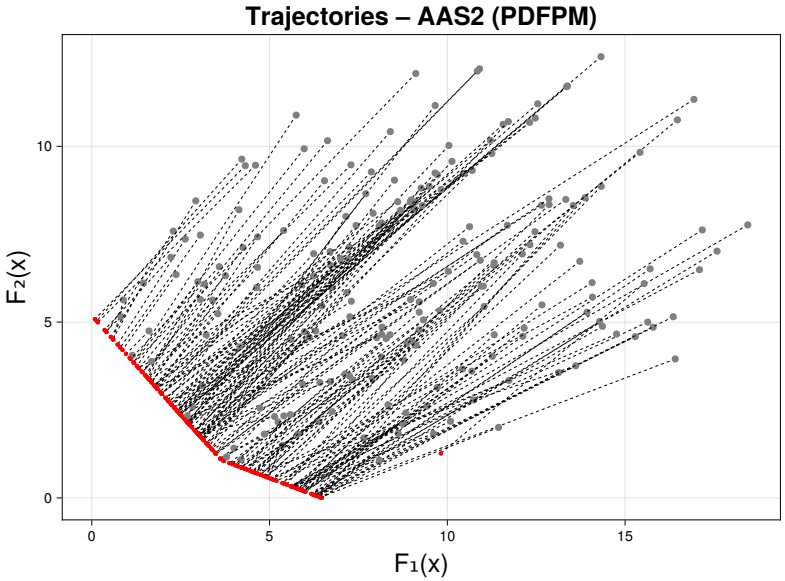

Observação:

→ CondG e ProxGrad não convergiram no problema AAS2 em nossos experimentos.

→ Neste problema, ambas as funções objetivo possuem **gradientes Hölder**.

→ O método PDFPM permanece aplicável e aproxima com sucesso a fronteira de Pareto.

Efeito da incerteza

As figuras a seguir ilustram o efeito do aumento dos níveis de incerteza δ nas frentes de Pareto reconstruídas.

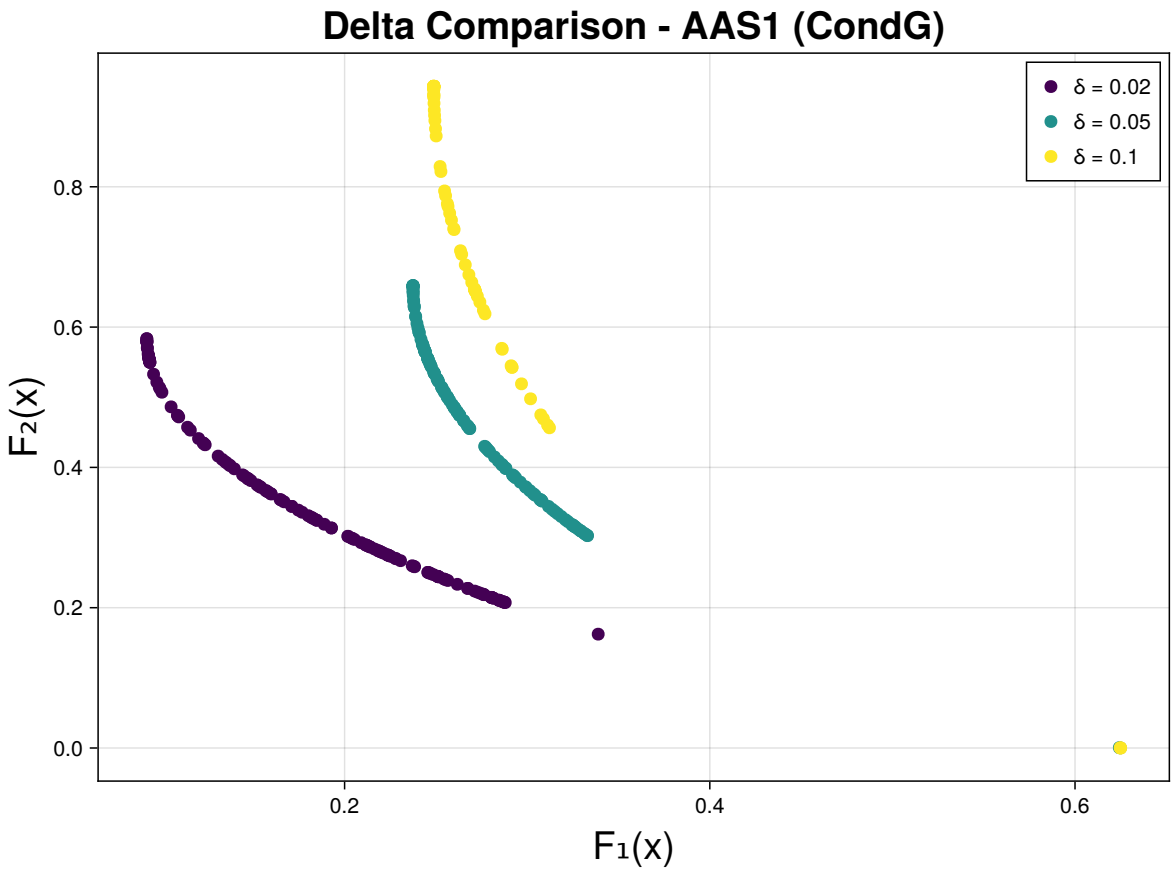

$\rightarrow$ **AAS1 – CondG:** reconstrução para valores crescentes de δ.

Efeito da incerteza

As figuras a seguir ilustram o efeito do aumento dos níveis de incerteza δ nas frentes de Pareto reconstruídas.

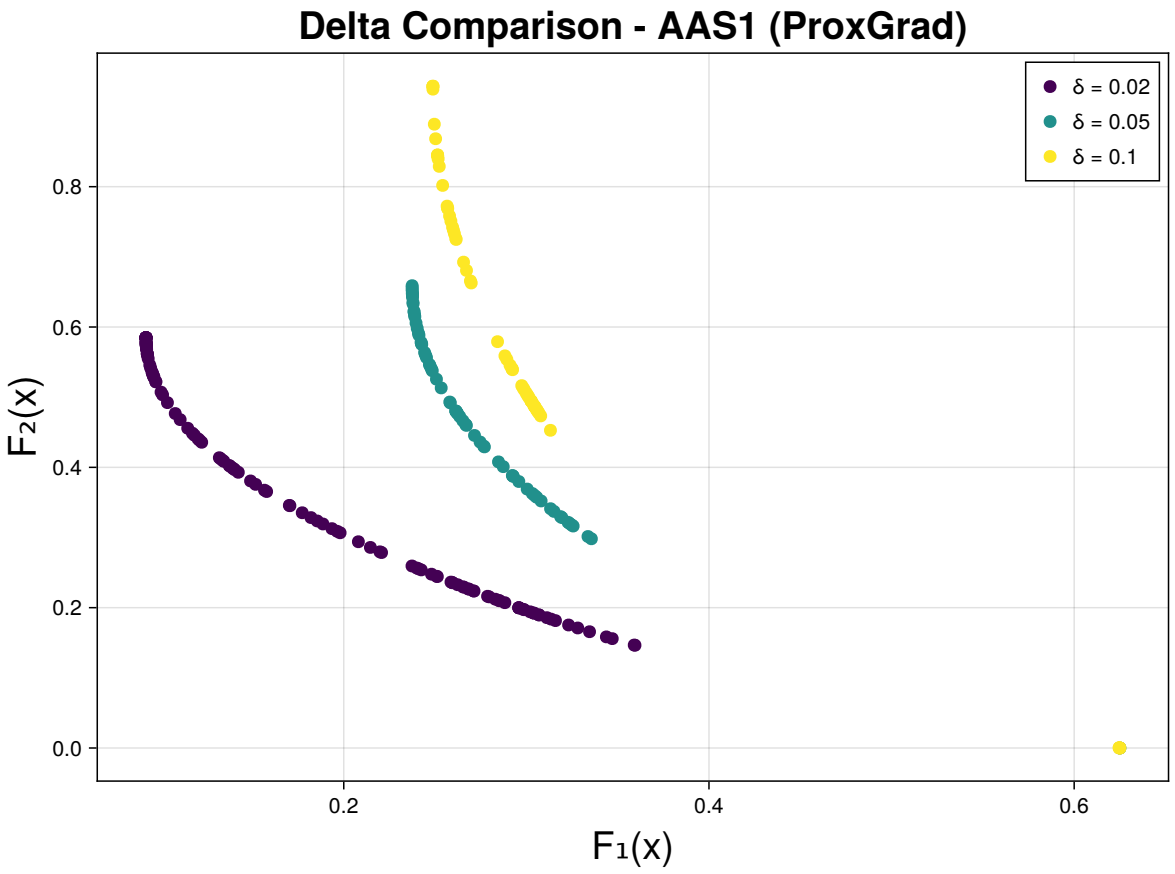

$\rightarrow$ **AAS1 – ProxGrad:** reconstrução para valores crescentes de δ.

Efeito da incerteza

As figuras a seguir ilustram o efeito do aumento dos níveis de incerteza δ nas frentes de Pareto reconstruídas.

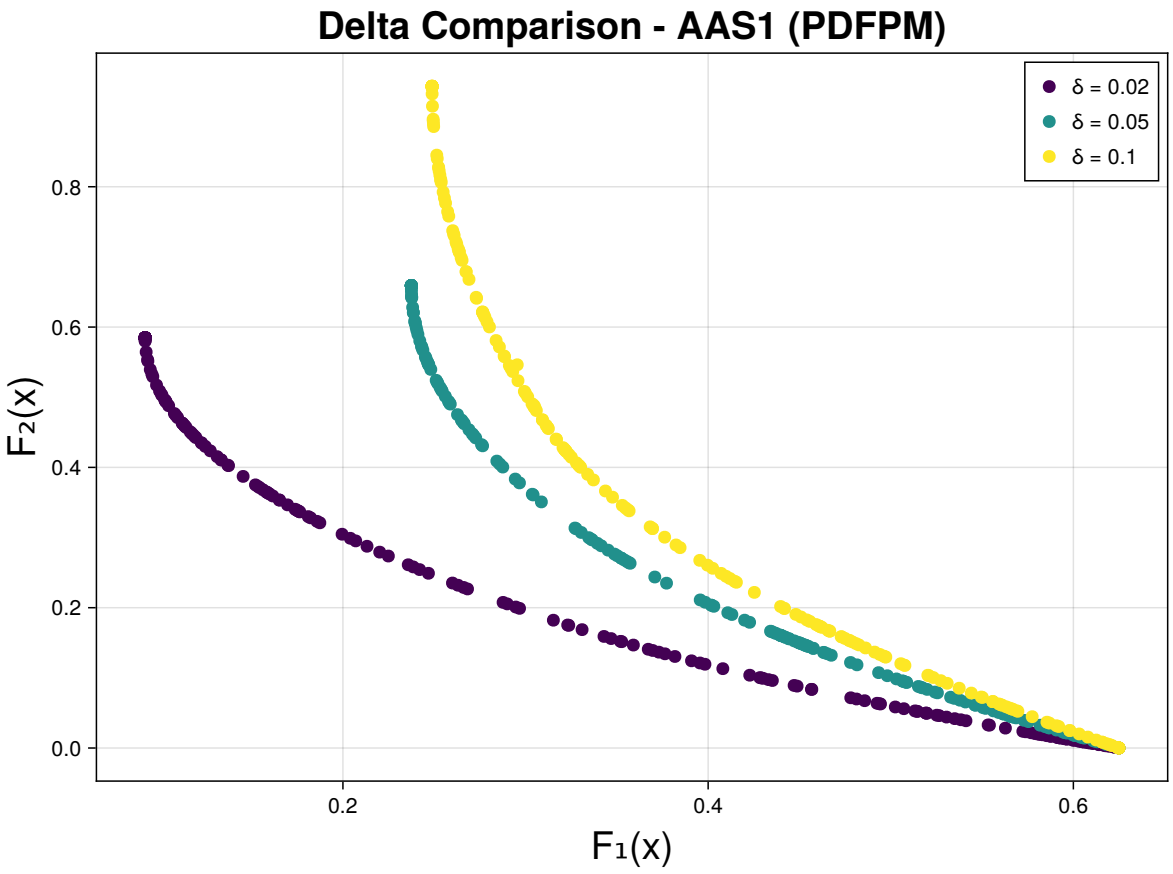

$\rightarrow$ **AAS1 – PDFPM:** reconstrução para valores crescentes de δ.

Efeito da incerteza

As figuras a seguir ilustram o efeito do aumento dos níveis de incerteza δ nas frentes de Pareto reconstruídas.

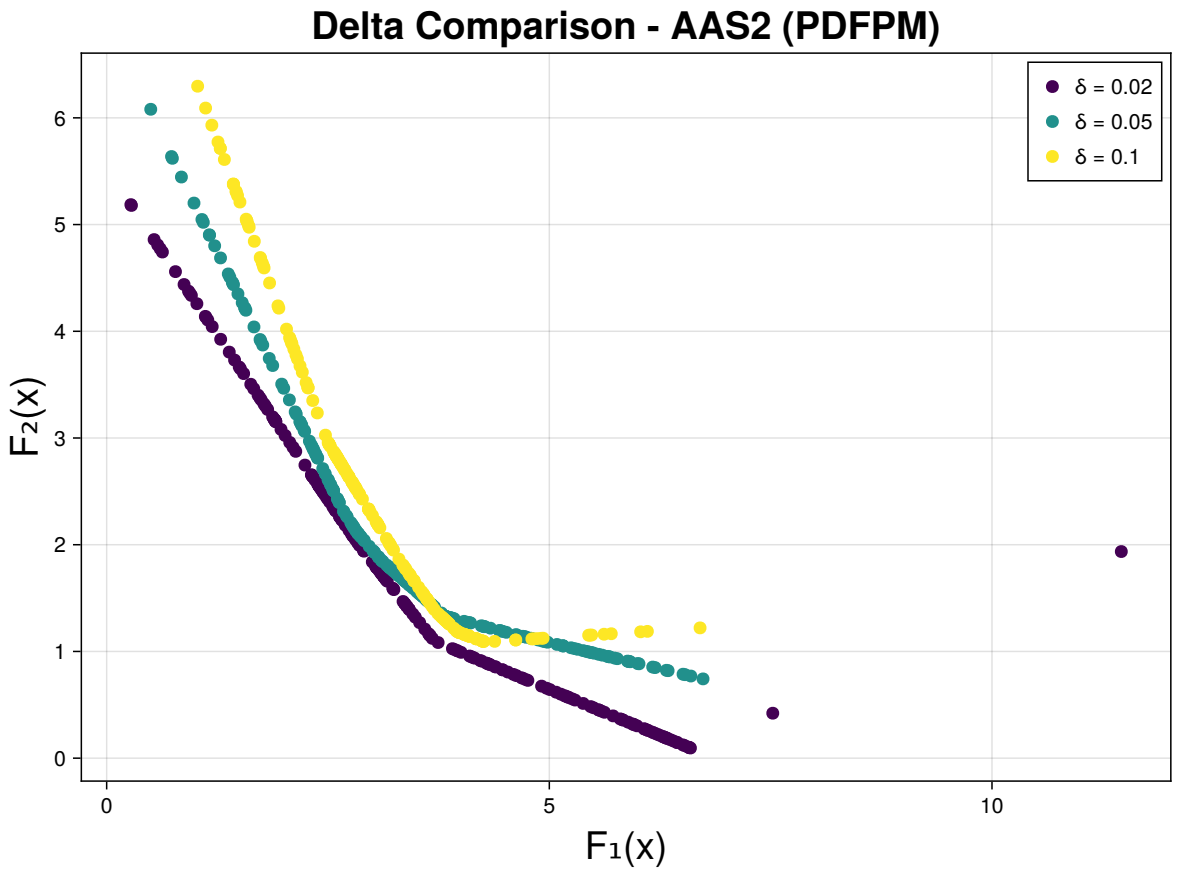

→ **AAS2 – PDFPM only:** CondG e ProxGrad não convergiram.

Conclusões

→ O PDFPM funciona bem para problemas multiobjetivo em que:

- todos os f_j possuem gradientes Lipschitz;
- todos os f_j possuem gradientes Hölder;
- ou há uma combinação de gradientes Lipschitz e Hölder.

→ Os resultados de complexidade são consistentes com a literatura sob condições de Hölder.

- Coincidem com a complexidade do método proposto por Calderón et al.[7] quando $p = 1$.
- Para $m = 1$, recupera-se a complexidade clássica dos métodos de regularização quadrática propostos por Martínez[8].

[7] Calderón, L., Diniz-Ehrhardt, M.A., Martínez, J.M.: On high-order model regularization for multiobjective optimization. Optimization Methods and Software 37(1), 175–191 (2022)

[8] Martínez, J.M.: On high-order model regularization for constrained optimization. SIAM Journal on Optimization 27(4), 2447–2458 (2011)

Conclusões

→ O método não requer informação prévia sobre as constantes de Lipschitz e de Hölder.

→ Resultados numéricos:

- Excelentes taxas de sucesso em problemas robustos multiobjetivo para todos os níveis de incerteza testados.
- Desempenho estável mesmo na presença de gradientes Hölder.
- Competitivo com outros métodos para otimização multiobjetivo composta (ProxGrad e CondG).

Muito obrigado pela atenção!

vitalianoamaral@ufpi.edu.br | https://vitalianoamaral.github.io/

QR code para acessar o artigo (arXiv)

QR code para acessar o repositório com os códigos (GitHub)