

# Complexidade e convergência de algoritmos de descida coordenadas de alta ordem para minimização com restrições de caixa.

Vitaliano S. Amaral - UFPI

V Congresso Brasileiro de Jovens Pesquisadores em  
Matemática - V CBJME

UFMG

11 de Setembro de 2024

# Sumário

1. Breve introdução aos métodos de descida coordenada - CD
2. Um método CD para problema restrito a uma caixa
3. Convergência
4. A complexidade do método
5. Comentários

Inicialmente consideramos o seguinte problema:

$$\text{Minimizar } f(x) \text{ sujeito a } x \in \Omega \subset \mathbb{R}^n.$$

Basicamente um método CD para resolver o problema acima consiste no seguinte:

### Algoritmo 1.

Dados  $k \leftarrow 0$ ,  $x^0 \in \Omega$ .

*Repetir os seguintes passos:*

**Passo 1.** Dado  $x^k$  escolher  $I_k \subset \{1, 2, \dots, n\}$ ;

**Passo 2.** Determinar  $x^{k+1} \in \Omega$ , com  $x_i^{k+1} = x_i^k$  para  $i \notin I_k$  de modo que satisfaça alguma condição ( pode ser decréscimo em  $f$ ). Após isso voltar ao Passo 1.

Por um bom tempo, esses métodos receberam pouca atenção por parte dos pesquisadores.

Dois dos motivos foram:

1. Baixo desempenho em muitos problemas da época.
2. Falta de desafios em termos de teoria de convergência.

A situação mudou drasticamente nas últimas décadas. Dentre vários motivos, destacamos:

1. O surgimento de problemas de grande porte em que os métodos CD se mostraram úteis para resolvê-los.
2. A necessidade de teorias esclarecedoras sobre os métodos CD.

Alguns dos trabalhos que contribuíram com essa retomada:



A. Beck e L. Tetruashvili (2013). - *On the convergence of block coordinate descent type methods*. SIAM Journal on Optimization, 23(4):2037-2060.



Foi estudado problema irrestrito onde a função objetivo possui gradiente Lipschitz. Considerando  $f$  convexa obtiveram bons resultados de convergência.



S. J. Wright. - *Coordinate descent algorithms*. Mathematical Programming, 151(1):3-34, 2015

Foi analisado abordagens tradicionais e avanços modernos na introdução e análise dos métodos CD. Wright deu uma atenção especial a problemas que surgem com frequência em aplicações de aprendizado de máquina.

Recentemente surgiram vários trabalhos sobre os métodos CD.  
Por exemplo, os trabalhos:

-  V. S. Amaral; R. Andreani; E. J. G. Birgin; D. S. Marcondes and J. M. Martínez. - *On complexity and convergence of high-order coordinate descent algorithms for smooth nonconvex box-constrained minimization*. Journal of Global Optimization (2022): 1-35
-  E. G. Birgin, and J. M. Martínez. - *Block coordinate descent for smooth nonconvex constrained minimization*. Computational Optimization and Applications 83.1 (2022): 1-27.
-  I. Necoara and F. Chorobura. - *Random Coordinate Descent Methods for Nonseparable Composite Optimization*. SIAM Journal on Optimization. 33, 2160-2190 (2023)

O restante desta apresentação é dedicado ao trabalho<sup>1</sup>, onde foi considerado o seguinte problema:

$$\text{Minimize } f(x) \text{ subject to } x \in \Omega, \quad (1)$$

onde  $\Omega \subset \mathbb{R}^n$  é dado por  $\Omega = \{x \in \mathbb{R}^n \mid \mathbf{l} \leq x \leq \mathbf{u}\}$ , e  $\mathbf{l}, \mathbf{u} \in \mathbb{R}^n$  são tais que  $\mathbf{l} < \mathbf{u}$ .

---

<sup>1</sup>V. S. Amaral; R. Andreani; E. J. G. Birgin; D. S. Marcondes and J. M. Martínez.  
- *On complexity and convergence of high-order coordinate descent algorithms for smooth nonconvex box-constrained minimization*. Journal of Global Optimization (2022): 1-35

Consideramos:

- ▶  $f$  com derivadas primeiras contínuas em  $\Omega$ .
- ▶  $g_P(x) = P_\Omega(x - \nabla f(x)) - x$  para todo  $x \in \Omega$ , onde  $P_\Omega$  é a projeção euclidiana em  $\Omega$ .
- ▶  $g_{P,I}(x) \in \mathbb{R}^n$  definida por

$$[g_{P,I}(x)]_i = \begin{cases} [g_P(x)]_i, & \text{se } i \in I, \\ 0, & \text{se } i \notin I. \end{cases}$$

- ▶  $M_{\bar{x}}(\cdot)$  uma aproximação de  $f$  em torno de  $\bar{x}$ .



Introduzimos o seguinte método para resolver o Problema (1):

## Algoritmo 2.

Suponha  $p \in \{1, 2, 3, \dots\}$ ,  $\alpha > 0$ ,  $\sigma_{\min} > 0$ ,  $\tau_2 \geq \tau_1 > 1$ ,  $\theta > 0$  e  $x_0 \in \Omega$  sejam fornecidos. Inicialize  $k \leftarrow 0$  e  $\sigma_0 \leftarrow 0$ .

**Passo 1.** Escolha um conjunto não vazio  $I_k \subseteq \{1, \dots, n\}$ .

**Passo 2.** Calcule  $x^{trial} \in \Omega$ ,  $x_i^{trial} = x_i^k$  para todos  $i \notin I_k$  tal que

$$M_{x^k}(x^{trial}) + \sigma_k \|x^{trial} - x^k\|^{p+1} \leq M_{x^k}(x^k)$$

e

$$\|P_{\Omega} [x^{trial} - \nabla (M_{x^k}(x) + \sigma_k \|x - x^k\|^{p+1}) \big|_{x=x^{trial}}] - x^{trial}\| \leq \theta \|x^{trial} - x^k\|^p.$$

**Passo 3.** Se

$$f(x^{trial}) \leq f(x^k) - \alpha \|x^{trial} - x^k\|^{p+1},$$

definir  $x^{k+1} = x^{trial}$ ,  $\sigma_{k+1} = \sigma_k$  e voltar ao Passo 1. Caso contrário, atualize  $\sigma_k \leftarrow \max\{\sigma_{\min}, \tau \sigma_k\}$  com  $\tau \in [\tau_1, \tau_2]$  e voltar ao Passo 2.

Assumimos a seguinte Suposição:

## Suposição 1.

*Para todo  $x \in \mathbb{R}^n$  existe  $L > 0$  tal que*

$$\|\nabla f(x) - \nabla M_{\bar{x}}(x)\| \leq L\|x - \bar{x}\|^p,$$

$$M_{\bar{x}}(\bar{x}) = f(\bar{x}) \quad \text{e} \quad f(x) \leq M_{\bar{x}}(x) + L\|x - \bar{x}\|^{p+1}.$$

## Observação 1.

*Para satisfazer a Suposição 1,  $M_{\bar{x}}(\cdot)$  pode ser:*

- ▶ *o polinômio de Taylor de ordem  $p$  de  $f$  ao redor de  $\bar{x}$  se as derivadas de ordem  $p$  de  $f$  satisfazem condições de Lipschitz.*
- ▶ *a própria  $f$ . Neste caso,  $p$  pode ser arbitrariamente grande, mas apenas as primeiras derivadas de  $f$  precisam existir.*

## Teorema 1.

*Suponha que a Suposição 1 seja válida. Se  $\sigma_k \geq L + \alpha$ , então o ponto  $x^{k+1}$  calculado pelo Algoritmo 2 está bem definido e satisfaz*

$$f(x^{k+1}) \leq f(x^k) - \alpha \|x^{k+1} - x^k\|^{p+1} \quad (2)$$

e

$$\|\nabla g_{P, I_k}(x^{k+1})\| \leq (L + \tau_2(L + \alpha)(p + 1) + \theta) \|x^{k+1} - x^k\|^p. \quad (3)$$

As provas de (2) e (3) seguem quase que diretamente das condições do Passo 2 e da Suposição 1.

## Teorema 2.

*Suponha que a Suposição 1 seja válida. Seja  $\{x^k\}$  a sequência gerada pelo Algoritmo 2. Então,*

$$\lim_{k \rightarrow \infty} \|x^{k+1} - x^k\| = 0, \quad (4)$$

$$\lim_{k \rightarrow \infty} \|\nabla g_{P, I_k}(x^{k+1})\| = 0, \quad (5)$$

e

$$\lim_{k \rightarrow \infty} \|\nabla g_{P, I_k}(x^k)\| = 0. \quad (6)$$

## Resumo da prova:

- ▶ Prova de (4):  $\Omega$  é compacto  $\implies f$  é limitada em  $\Omega$   
 $\implies \lim_{k \rightarrow \infty} (f(x^k) - f(x^{k+1})) = 0 \stackrel{(2)}{\implies} \lim_{k \rightarrow \infty} \|x^{k+1} - x^k\| = 0.$
- ▶ Prova de (5): Segue direto de (3) e (4).
- ▶ Prova de (6): De  $\Omega$  compacto e continuidade do gradiente, temos que  $\|\nabla g_{P,I}(x)\|$  é uniformemente contínua. Daí, passando limite em

$$\|\nabla g_{P,I}(x^k)\| \leq \|\nabla g_{P,I}(x^k) - \nabla g_{P,I}(x^{k+1})\| + \|\nabla g_{P,I}(x^{k+1})\|,$$

usando (4) e (5) obtemos (6).

## Observação 2.

*Observe que os resultados anteriores não garantem*

$$\lim_{k \rightarrow \infty} \|g_P(x^k)\| = 0. \quad (7)$$

Para provar (7) foi necessário a seguinte suposição.

## Suposição 2.

*Existe  $\bar{m} < +\infty$  tal que, para todo  $i \in \{1, \dots, n\}$ :*

- 1. Existe  $k \leq \bar{m}$  tal que  $i \in I_k$ ;*
- 2. Para qualquer  $k \in \mathbb{N}$ , se  $i \in I_k$ , então existe  $m \leq \bar{m}$  tal que  $i \in I_{k+m}$ .*

Note que a Suposição 2 nos permite escolher o bloco de coordenadas em cada iteração de diversas formas, basta que, a cada  $\bar{m}$  iterações, todos os blocos sejam escolhidos pelo menos uma vez.

## Teorema 3.

*Suponha que as Suposições 1 e 2 sejam válidas. Seja  $\{x^k\}$  a sequência gerada pelo Algoritmo 2. Então,*

$$\lim_{k \rightarrow \infty} \|\nabla g_P(x^k)\| = 0. \quad (8)$$

*Além disso, se  $x^* \in \Omega$  for um ponto de acumulação de  $\{x^k\}$ , então temos que  $\|\nabla g_P(x^*)\| = 0$ .*

**Resumo da prova:** Seja  $i \in \{1, \dots, n\}$ . Pela Suposição 2, existe um conjunto  $K = \{k_1, k_2, k_3, \dots\}$  tal que  $i \in I_{k_\ell}$  para todo  $\ell = 1, 2, 3, \dots$ . Dado  $I \subseteq \{1, \dots, n\}$ , de (6) temos,

$$\lim_{k \in K} [\nabla g_P(x^k)]_i = \lim_{k \in K} \nabla g_{P,I}(x^k)_i = 0 \text{ para todo } i \in I. \quad (9)$$

Seja  $j \in \{1, 2, \dots\}$  arbitrário. De (9) e da continuidade uniforme de  $\nabla g_P$ , temos

$$\begin{aligned} \lim_{k \in K} |[\nabla g_P(x^{k+j})]_i| &\leq \lim_{k \in K} |[\nabla g_P(x^{k+j})]_i - [\nabla g_P(x^k)]_i| \\ &+ \lim_{k \in K} |[\nabla g_P(x^k)]_i| = 0. \end{aligned}$$

Em particular, isto é válida para todo  $j = 1, \dots, \bar{m}$ . Isso implica que

$$\lim_{k \rightarrow \infty} [\nabla g_P(x^k)]_i = 0.$$

Portanto

$$\lim_{k \rightarrow \infty} \|\nabla g_P(x^k)\| = 0.$$

Assim, temos que todo ponto de acumulação é ponto estacionário.



Dado uma tolerância  $\epsilon > 0$ , desejamos saber o esforço computacional máximo necessário para obter um iterado  $x^k$  na qual a função objetivo seja menor que um dado alvo ou  $\|g_P(x^k)\|$  seja menor que  $\epsilon$ .

## Teorema 4.

Suponha que a Suoiscção 1 seja válida. Seja  $f_{target} < f(x^0)$  e  $\epsilon > 0$  dados. Então, a quantidade máxima de iterações  $k$  para obter

- (i)  $f(x^{k+1}) \leq f_{target}$  ou
- (ii)  $|[g_P(x^{k+1})]_i| \leq \epsilon$  para todo  $i \in I_k$  é

$$\frac{f(x^0) - f_{target}}{c} e^{-\frac{p+1}{p}}, \quad (10)$$

onde  $c$  depende apenas de  $\alpha$ ,  $\tau_2$ ,  $L$ ,  $p$ , e  $\theta$ .

**Resumo da prova:** Substituindo  $|[g_P(x^{k+1})]_i| > \epsilon$  em (2) obtemos

$$f(x^{k+1}) \leq f(x^k) - c\epsilon^{\frac{p+1}{p}}.$$

Daí e de  $f(x^{k+1}) > f_{\text{target}}$  obtemos que

$$k \leq \frac{f(x^0) - f_{\text{target}}}{c} \epsilon^{-\frac{p+1}{p}}.$$

### Observação 3.

*O resultado anterior se refere a obter  $|[g_P(x^{k+1})]_i| \leq \epsilon$  para todos  $i \in I_k$ . Para obter  $|[g_P(x^{k+1})]_i| \leq \epsilon$  para todos  $i \notin I_k$  precisamos que as iterações consecutivas estejam suficientemente próximas.*

## Teorema 5.

Suponha que a Suposição 1 seja válida. Seja  $f_{\text{target}} < f(x^0)$ ,  $\epsilon > 0$ , e  $\delta > 0$  dados. Então, a quantidade de iterações para obter

(i)  $f(x^{k+1}) \leq f_{\text{target}}$  ou

(ii)  $\|x^{k+1} - x^k\| \leq \delta$  e  $|[g_p(x^{k+1})]_i| \leq \epsilon$  para todo  $i \in I_k$

é no máximo

$$\frac{f(x^0) - f_{\text{target}}}{c \epsilon^{\frac{p+1}{p}}} + \frac{f(x^0) - f_{\text{target}}}{\alpha \delta^{p+1}},$$

onde  $c$  depende apenas de  $\alpha$ ,  $\tau_2$ ,  $L$ ,  $p$ , e  $\theta$ .

**Resumo de prova:** A prova segue direto de (ii), de  $f(x^{k+1}) \leq f(x^k) - \alpha \|x^{k+1} - x^k\|^{p+1}$  e do Teorema 4.

Agora dividimos as iterações em ciclos, onde cada ciclo possui  $\overline{m}$  iterações.

- ▶ os ciclos sucessivos começam em  $x^0, x^{\overline{m}}, x^{2\overline{m}}, \dots, x^{l\overline{m}}, \dots$
- ▶ As iterações  $k = l\overline{m}, \dots, l\overline{m} + \overline{m} - 1$  são internas ao ciclo  $l$ .

Com a noção de ciclo em mãos, reformulamos os Teoremas 4 e 5 da seguinte forma.

## Teorema 6.

*Suponha que as Suposições 1 e 2 sejam válidas. Seja  $f_{\text{target}} < f(x^0)$  e  $\epsilon > 0$  dados. Então, o número de ciclos  $l$  para obter uma iteração interna  $k$  tal que*

- (i)  $f(x^{k+1}) \leq f_{\text{target}}$  ou
- (ii)  $||g_P(x^{k+1})||_i \leq \epsilon$  para algum  $i \in I_k$  é no máximo

$$\frac{f(x^0) - f_{\text{target}}}{c} \epsilon^{-\frac{p+1}{p}}, \quad (11)$$

onde  $c$  depende apenas de  $\alpha, \tau_2, L, p$ , e  $\theta$ .

**Resumo da prova:** A prova segue direto do Teorema 4.

## Teorema 7.

Suponha que as Suposições 1 e 2 sejam válidas. Seja  $f_{\text{target}} < f(x^0)$ ,  $\epsilon > 0$ , e  $\delta > 0$  dados. Então, o número de ciclos  $l$  para obter uma iteração  $k$  tal que

$$(i) \quad f(x^{k+1}) \leq f_{\text{target}} \text{ ou}$$

$$(ii) \quad \|x^{k+1} - x^k\| \leq \delta \text{ e } |[g_P(x^{k+1})]_i| \leq \epsilon \text{ para algum } i \in I_k$$

é no máximo

$$\frac{f(x^0) - f_{\text{target}}}{c \epsilon^{\frac{p+1}{p}}} + \frac{f(x^0) - f_{\text{target}}}{\alpha \delta^{p+1}}, \quad (12)$$

onde  $c$  depende apenas de  $\alpha$ ,  $\tau_2$ ,  $L$ ,  $p$ , e  $\theta$ .

**Resumo da prova:** A prova segue diretamente dos Teoremas 4-6.

A suposição a seguir garante que pequenos incrementos causam pequenas diferenças nos gradientes projetados.

### Suposição 3.

Existe  $L_g > 0$  tal que para todo  $i = 1, \dots, n$  e  $x, z \in \Omega$ ,

$$|[g_P(x)]_i - [g_P(z)]_i| \leq L_g \|x - z\|.$$

A Suposição 3 é satisfeita se o gradiente de  $f$  satisfaz a condição de Lipschitz com constante  $L_g$ .

Agora somos capazes de estabelecer um limite para o número de ciclos em que todo o gradiente projetado é maior que uma tolerância dada.

## Teorema 8.

Suponha que as Suposições 1-3 sejam válidas. Seja  $f_{target} < f(x^0)$ ,  $\epsilon > 0$ , e  $\delta > 0$  dados. Então, existe um ciclo  $l$  com

$$l \leq \frac{f(x^0) - f_{target}}{c \epsilon^{\frac{p+1}{p}}} + \frac{f(x^0) - f_{target}}{\alpha \delta^{p+1}} + 1 \quad (13)$$

tal que:

- (i) para alguma iteração  $k$  interna ao ciclo  $l$ , temos  $f(x^k) \leq f_{target}$ , ou
- (ii) para todas as iterações  $k$  internas ao ciclo  $l$ , temos que

$$|[g_P(x^{k+1})]_i| \leq \epsilon + \overline{m}L_g\delta \quad \text{para todo } i = 1, \dots, n.$$

**Resumo da prova:** Pelo Teorema 7, existe um ciclo  $l$  satisfazendo (13), tal que, para cada iteração  $k$  interna ao ciclo  $l$ ,

$$f(x^{k+1}) \leq f_{\text{target}} \text{ ou}$$

$$\|x^{k+1} - x^k\| \leq \delta \quad \text{e} \quad |[g_P(x^{k+1})]_i| \leq \epsilon \quad \text{para todo } i \in I_k. \quad (14)$$

► Se existir uma iteração  $k$  interna a  $l$  tal que  $f(x^{k+1}) \leq f_{\text{target}}$ , ok.  
Neste caso o Teorema é válido.



- Suponha (14) válido e seja  $i \in \{1, \dots, n\}$  arbitrário.  
Da Suposição 2 existe uma iteração  $k$  em  $l$  tal que  $i \in I_k$ , daí e de (14), temos  $|[g_P(x^{k+1})]_i| \leq \epsilon$ . Para qualquer iterado  $z$  em  $l$ , temos

$$\begin{aligned} |[g_P(z)]_i| &\leq |[g_P(x^{k+1})]_i| + |[g_P(z)]_i - [g_P(x^{k+1})]_i| \\ &\leq \epsilon + L_g \|z - x^{k+1}\| \\ &\leq \epsilon + L_g \sum_{j=0}^{\overline{m}-1} \|x^{l\overline{m}+j} - x^{l\overline{m}+j+1}\| \\ &\leq \epsilon + \overline{m}L_g\delta. \end{aligned}$$

Finalizando a prova.

Substituindo  $\epsilon$  por  $\epsilon/2$  e definindo  $\delta = \epsilon/(2\overline{m}L_g)$ , o Teorema 8 pode ser reescrito da seguinte forma.

## Teorema 9.

*Suponha que as suposições 1, 2 e 3 sejam válidas. Seja  $f_{\text{target}} < f(x_0)$ ,  $\epsilon > 0$ , e  $\delta > 0$  dados. Então, existe um ciclo  $l$  não maior que*

$$\frac{f(x_0) - f_{\text{target}}}{2^{-\frac{p+1}{p}} c} \epsilon^{-\frac{p+1}{p}} + \frac{[f(x_0) - f_{\text{target}}] \overline{m}^{p+1}}{\alpha(2\overline{L})^{-(p+1)}} \epsilon^{-(p+1)} + 1, \quad (15)$$

*onde  $c$  depende apenas de  $\alpha$ ,  $\tau_2$ ,  $L$ ,  $p$  e  $\theta$ , tal que, na sua primeira iteração interna  $k$ ,*

$$f(x^k) \leq f_{\text{target}} \text{ ou } |[g_p(x^{k+1})]_i| \leq \epsilon \quad \text{para todo } i = 1, \dots, n.$$

No resultado anterior, não levamos em consideração o número de vezes em que o parâmetro de regularização é atualizado.

Observe que:

- ▶ Por definição, a sequência de  $\sigma_k$  é limitada inferiormente pela sequência  $0, \tau_1^0 \sigma_{\min}, \tau_1^1 \sigma_{\min}, \tau_1^2 \sigma_{\min}, \tau_1^3 \sigma_{\min}, \dots$
- ▶ Sendo  $r$  o número máximo de vezes em que o parâmetro de regularização é atualizado, logo

$$\tau_1^{r-2} \sigma_{\min} \leq L + \alpha, \text{ pois na pior das hipóteses } \tau_1^{r-1} \sigma_{\min} \geq L + \alpha.$$

De onde segue que

$$r \leq \log_{\tau_1} \left( \frac{L + \alpha}{\sigma_{\min}} \right) + 2.$$

O número de ciclos para obter  $f(x^k) \leq f_{\text{target}}$  ou  $||[g_P(x^{k+1})]_i| \leq \epsilon$  para todo  $i = 1, \dots, n$  é no máximo

$$\frac{f(x_0) - f_{\text{target}}}{2^{-\frac{p+1}{p}} c} \epsilon^{-\frac{p+1}{p}} + \frac{[f(x_0) - f_{\text{target}}] \bar{m}^{p+1}}{\alpha(2\bar{L})^{-(p+1)}} \epsilon^{-(p+1)} + 1. \quad (16)$$

Alguns pontos sobre (16):

1.  $p$  cresce  $\implies$  a complexidade piora, o contrário dos métodos tradicionais.
2.  $\bar{m}$  cresce  $\implies$  o segundo termo de (15) cresce.
3.  $\bar{m}$  crescer junto com  $n$  se o tamanho dos subproblemas permanecer limitado.
4. O tipo de escolha do bloco pode influenciar na complexidade.

Com, isso, os resultado de complexidade obtido é um argumento para descartar algoritmos CD de alta ordem?

OBRIGADO A TODOS PELA PACIÊNCIA!!